




目录列表可在ScienceDirect上获取

太阳能

期刊主页: www.elsevier.com/locate/solener



用于预测发光太阳能聚光器中光学转换效率的人工神经网络

P.S. 安德夫^{a,*}, L.M.S. 迪亚斯^{a,b}, S.F.H. 科雷亚^c, A.N. 卡内罗·内托^b, R.A.S. 费雷拉^{b,*}

^a 电气与计算机工程系和电信研究所, 高等技术学院, 里斯本大学, 1049-001 里斯本, 葡萄牙

^b 物理学系和 CICECO, 阿维罗材料研究所, 阿维罗大学, 3810-193 阿维罗, 葡萄牙

^c 通信研究所和阿威罗大学, 3810-193 阿威罗, 葡萄牙

文章信息

ABSTRACT

Keywords:

人工神经网络 (ANN) 发光太阳能聚光器 (LSC) 光学转换效率

开发能够将阳光塑形以适应光伏 (PV) 电池吸收区域的光捕获材料, 为利用光谱转换器 (如发光太阳能聚光器 (LSCs)) 提供了机会。本研究探索了利用人工神经网络 (ANNs) 预测光谱转换器的光学转换效率, 基于其生产中使用的材料特性, 而无需进行昂贵且耗时的实验测试。为了预测效率作为材料和制造过程函数, 使用先前记录的物理实现数据对 ANNs 进行了训练。研究表明, 隐藏层具有 97 和 19 个神经元的 ANNs 能够提供准确的效率预测, 使其成为设计和优化光谱转换系统的宝贵工具。所提出的模型经过验证, 其光学转换效率的均方误差在 10^{-5} 量级。训练的 ANNs 为预测光谱转换器的光学效率引入了一种新方法, 为机器学习作为材料设计决策工具的应用打开了大门, 并消除了对物理设备实现的必要性。

1. 简介

对更节能的城市和社区的持续需求正在推动实现零能耗建筑 (ZEBs) [1], 的策略研究和开发, 因为建筑是能源消耗最大的部门之一, 与工业和交通部门[2,3]并列。零能耗建筑的实施需要提高能源效率和利用可再生能源 [1]。在这方面, 光伏 (PV) 器件的增强及其在现有建筑中的集成至关重要, 因为太阳是主要的可再生能源来源[4]。

所有光伏器件, 无论是商业化还是仍处于新兴阶段, 其主要限制之一就是无法有效收集太阳光谱中所有可用的光子。为了解决这个问题, 可以应用光谱转换器, 因为它们利用光致发光过程来捕获光伏电池无法利用的低能或高能光子, 并将它们转换为具有有用能量的光子 [5]。这些可以表现为直接施加在光伏电池表面上的层状结构, 作为增强光伏性能的附加设备 (图1a), 或者发光太阳能聚光器 (LSCs), 它们可以用

建筑环境, 因为它们可以嵌入建筑立面或窗户 (图1b), 允许产生额外的能量。LSCs由掺杂或涂覆有发光材料的平面波导组成, 这些材料在大面积上吸收阳光, 将其转换并集中到较小面积上, 然后将其导向太阳能电池, 在那里将其转换为电能 [6]。对建筑集成光伏器件的兴趣日益浓厚, 作为一种解决方案, 可以将太阳能发电纳入现有建筑环境的元素中, 利用研究来寻找具有高效率的光谱转换解决方案 [7], specially LSCs, 因为它们可以被视为最有前景的技术之一, 用于半透明器件, 这些器件可以集成到建筑环境中, 而不会对建筑的美观或居民的生活质量产生不利影响, 在实现所谓的净零能建筑 [8-10] 方面占据重要地位。然而, 由于各种因素, 如发光材料的加工和光学特性以及几何形状, 预测和优化其性能可能具有挑战性。为了应对这些挑战, 需要采用跨学科方法, 结合材料科学、光学和光伏器件的专业知识。

材料科学与技术正面临着数字转型的冲击, 许多其他领域尚未经历。数字

* 通讯作者。电子邮件地址: paulo.andre@lx.it.pt (P.S. Andr'e), rferreira@ua.pt (R.A.S. Ferreira)。

命名法		α	学习率
缩写		$J O$	代价函数
PV	光伏	θ	待优化的参数
LSC	发光太阳能聚光器	R^2	确定系数
ANN	人工神经网络	n	样本点数量
ZEB	零能耗建筑	$\hat{Y}$	估计值
ML	机器学习	Y	测量/报告值
PCE	功率转换效率	i	输入层
PMMA	聚甲基丙烯酸甲酯	h_1	第一隐藏层
SEBS	苯乙烯-乙烯/丁烯-苯乙烯嵌段共聚物	h_2	第二隐藏层
PDMS	聚二甲基硅氧烷	o	输出层
PVP	聚乙吡咯烷酮	发光太阳能聚光器符号	
t-U(5000)	三脲硅有机-无机杂化	η_{opt}	光学转换效率
d-U(600)	二脲硅有机-无机杂化	η_{yield}	绝对发射量子产率
CD	碳点	N_{Emi}	发射光子数
QD	量子点	P_{out}	输出光功率
MSE	均方误差	N_{Abs}	吸收光子数
MAE	平均绝对误差	P_{in}	光功率
Ln	镧系元素	A_p	峰值吸收波长
机器学习		A_{min}	吸收光谱带的最小波长值
$y_k^l(n)$	g 符号 k - th 神经元在 l - th 层的输出信号	A_{max}	最大波长
$w_{kv}^l(n)$	l -层 k -神经元与 $(l-1)$ -层之间的权重 v - 神经元	g 吸收的 th 值	
l	层	band	
k	k 神经元	E_{min}	发射光谱带的最低波长值
v	v 神经元	E_p	峰值发射的波长值
		E_{max}	发射光谱带的最高波长值
			ption s pectral

创新已经引入了新的材料类别，这得益于其增强我们预测材料性能、活性分子性能甚至毒理学效应的能力。为了充分发挥这一潜力，有效利用人工智能和机器学习（ML）至关重要。ML在材料科学中的重要性日益凸显，这归因于其在处理复杂和海量数据集方面的专长。这些算法可以高效地处理和分析此类数据，使研究人员能够识别手动分析难以发现的模式和关系。在材料科学中，ML已被用于预测材料性能、优化材料合成和加工，以及加速新材料的开发[12]。

利用机器学习技术，Srivastava 等人 [13] 解决了混合有机-无机钙钛矿在环境压力下因组成依赖性降解的挑战，这阻碍了它们的商业可行性。为了规避在评估这些混合物在不同应力条件下行为时试验和错误方法的局限性，他们采用机器学习模型并结合原位光致发光数据来预测 $Cs_yFA_{1-y}Pb(Br_xI_{1-x})_3$ 对相对湿度循环的响应。三种模型，包括线性回归、回声状态网络 [14]，和带外生回归因子的季节性自回归积分滑动平均算法 [15]，已被定量比较。后者模型在预测 50 小时内光致发光变化方面达到了 90% 以上的准确率。值得注意的是，含 17% Cs 的样品在循环过程中始终表现出光致发光的增加。这些精确的时间序列预测可以扩展到其他系列的混合有机-无机钙钛矿，突出了机器学习方法在开发清洁能源应用材料方面的潜力。

人工神经网络（ANNs）是一种受大脑中生物神经网络结构和功能启发的机器学习算法，能够从输入输出数据中学习和泛化 [16]。ANNs 已被广泛用作一种强大的基于数据的方法

替代物理建模，并预测复杂问题的性能，例如，预测太阳能电池或其他光子器件的性能 [17]。ANNs 特别适用于图像和语音识别等任务，其中输入数据复杂且高维，它们在预测光谱转换器效率方面的应用是一个新且活跃的研究领域 [18]。采用 ANN 进行光谱转换器设计的主要优势之一是能够处理大型数据集并识别输入和输出变量之间的复杂非线性关系，从大型数据集中学习，并捕捉输入和输出变量之间可能传统模型不明显的关系。

近年来，人工神经网络（ANN）被用于高精度预测有机染料的吸收和发射光谱 [19]，有机分子的光物理性质 [20]，以及量子点的特性，包括吸收和发射光谱、尺寸分布和表面化学 [21]。类似地，遗传算法被用于最大化太阳能电池（LSCs）的功率转换效率（PCE）[22]。此外，太阳能收集研究利用人工神经网络预测与太阳能相关的不同方面，通过其他预测方法提高了22%的估计值 [23]。特别是，人工神经网络被用于预测不同环境条件下光伏电池的效率和功率输出，包括辐照度、温度和风速 [24]，以预测染料敏化太阳能电池的性能 [25] 以及推导每小时全球水平辐照度 [23,26]。太阳能领域的另一个研究方向是利用人工神经网络进行光伏电池的故障诊断和维护，包括阴影、组件失配和老化 [27]，根据电池的性能和环境条件预测所需的维护 [28]。最近，机器学习聚类被用于优化太阳能电池的设计，展示了超过1 MW•h•m⁻²•年的能源产量。

Chugh 等人 [30] 采用人工神经网络 (ANN) 计算固体核心光子晶体光纤 (PCF) 的光学特性，包括有效折射率、有效模式面积、色散和约束损耗。该 ANN 模型在预测这些特性方面表现出高精度。

Chugh 等人 [31], 采用人工神经网络 (ANN) 计算固体核心光子晶体光纤 (PCFs) 的光学特性, 包括有效折射率、有效模式面积、色散和约束损耗。ANN 模型在预测这些特性方面表现出高精度, 在典型参数范围内, 考虑了波长 (0.5–1.8 μm)、节距 (0.8–2.0 μm)、直径与节距比 (0.6–0.9) 以及二氧化硅固体核心 PCFs 中的环数 (4 或 5)。作者还展示了 ANN 在预测未知设备参数的光学特性方面的效率, 与传统数值模拟方法 (如有限差分法 [31]、有限元法 [32]、块迭代频域法 [33]、和平面波展开法 [34,35]) 相比, 计算运行时间更快。Lo Brano 等人 [36] 专注于开发一种神经网络预测模型, 用于评估碟形斯特林系统在发电方面的能量产出能力, 为不同安装地点的系统设计和尺寸提供工具。他们的方法使用真实数据进行训练, 而不是从解析或数值模型中得出的预测。探索了各种神经网络配置, 调整深度、神经元数量和计算资源以适应不同的输入变量。最成功的网络在将预测的电气输出功率与实验测量值进行比较时, 达到了高决定系数 (0.98), 证明了这些神经模型的可靠性。

总体而言, 人工神经网络 (ANNs) 在确定材料的语音特性方面已展现出巨大的潜力, 并越来越多地被学术界和工业界用于材料发现、设计和分析。它们在设计优化太阳能收集系统方面显示出巨大的潜力, 使研究人员能够快速探索广阔的设计空间, 并识别出能够提高效率和性能的光谱转换器的最佳配置。在光谱转换器是能够有效提高太阳能电池效率和/或集中入射太阳辐射的设备, 并且光谱转换器的光学效率是这些设备设计和优化中一个重要参数的前提下, 这项工作探索了一种突破性的多维方法, 该方法利用 ANNs 预测光谱转换器的性能, 主要关注液态硅太阳能电池 (LSCs)。重要的是, 这种方法同样适用于转换层, 因为主要的光学特性保持一致, 无需物理设备实现。在众多机器学习方法中选择 ANNs 是基于具体问题、数据可用性、计算资源和我们问题研究目标, 其中 ANNs 的复杂性和适应性可能提供显著优势 [v1]。




图 1. 在 (a) 下转换/下转换和 (b) 平面 LSCs 中发生的主要过程和损失: (1) 光活性中心的发射, (2) 入射太阳光的菲涅尔反射, (3) 表面散射, (4) 入射太阳光, (5) 直接透射辐射, (6) 邻近中心的再吸收, (7) 非辐射弛豫, (8) 逃逸锥内的发射 [11]。c) 掺杂罗丹明 6G 有机染料的 d-U(600) 的发射和吸收光谱。d) 数据集的 19 个特征的交叉相关性, 其归属在 (e) 中详细说明。

和适应性可能提供显著优势[37]。

虽然机器学习在光伏电池领域得到了广泛应用，但其在钙钛矿太阳能电池（LSCs）中的应用研究相对有限。因此，本研究有助于推动和加速该领域的发展，通过考虑本征光物理性质（吸收、发射和光学中心类型）和材料特性（化学主体和处理方法），提供了一个有价值的预测模型，用于光学效率。这里取得的成果的潜力将使我们能够获得一个简化的优化设计，用于影响光谱转换器件的各种参数，有可能推动整个太阳能行业进入一个新的增强能源捕获和利用的时代。

2. 方法论

2.1. 人工神经网络 (ANNs)

ANNs 是受生物神经网络结构和功能启发的机器学习算法，用于模拟输入和输出之间的复杂非线性关系，并且可以在解决各种问题时非常有效。本质上，典型的 ANN 结构由神经元（处理单元）和连接（神经元之间的互连）组成，这些连接由一个权重参数控制，该参数决定了连接的强度。当一个神经元从其他神经元接收刺激时，它会处理信息并产生输出。在本研究中，我们采用一个具有两个隐藏层的前馈 ANN 来模拟 LSCs 的关键参数与其效率之间的相关性。输出层中的神经元数量等于输出变量的数量，而输入节点对应于 LSC 材料的特性，以及入射和发射光的波长。网络的输出层由一个神经元组成，代表预测输出。

在此网络非线性的这种实现中，所有神经元使用的激活函数是 Sigmoid 函数，它计算 l^{th} 层 k^{th} 神经元的输出信号如下 [38]:

$$y_k^l(n) = \frac{1}{1 + e^{-\sum_{v=0}^{n_l-1} w_{kv}^l(n)}}$$
 (1)

其中 $w_{kv}^l(n)$ 是 l -层 k -神经元和 $(l-1)$ -层 v -神经元之间的权重。

每个神经元将其输入的加权和应用一个激活函数，产生一个输出值。网络通过一个称为反向传播 [39] 的过程来调整权重和激活函数。反向传播试图最小化预测输出和实际输出之间的误差，允许使用梯度下降 [40]，等优化算法迭代地调整权重和激活函数，通过将误差反向传播并通过网络更新权重。

2.2. 数据源

光学转换效率 (η_{opt}) 被选为预测输出参数，因为它是最常用于描述 LSCs（补充信息中的详细内容）性能的品质因数。用于训练和测试所提出算法的数据集 [41] (<https://figshare.com/s/23186603367d9c9483c0>) 来自一个由学术机构提供的公共存储库。选择的数据对应于数据集中可用条目总数的 56%，并且仅考虑与光活性中心和主体材料类型、处理方法和相应的吸收和发射特性（光谱区域和发射量子产率， η_{yield} ）相关的特征，以及相应的报告 η_{opt} 值（表 S1，补充信息）。

进行了一项初步分析，以确保所使用的数据集

在本研究中足够大，能够捕捉问题的复杂性并包含多样化的示例，这将使模型能够很好地泛化到新数据。现实世界的的数据通常带有缺失属性或与测量光学特性相关的值。因此，在将其用于所提出的 ANN 之前，通过清理和组织原始数据，并对问题域中的数据进行准确性、多样性和代表性进行预处理，将非常有益。在这种情况下，删除了数据集中缺失相关特征数据的行为，导致数据集包含 236 条记录（表 S1 和 S2，补充信息）。

百分之十八点二 (18.2 %) 的数据集被保留为验证集，包含 43 个示例（表 S2）。该验证集使用我们先前发表的结果数据构建，涵盖了广泛的转换效率范围，增强了我们对所用值的信心。其余 193 个示例（表 S1）用于特征选择和模型验证。我们在执行标准数据集分割流程后实施了 10 折交叉验证，以确定最佳的 ANN 架构和超参数。

下一步涉及使用 one-hot 编码将分类分类器转换为数值分类器。该过程为每个分类器生成了三个特征。此外，我们将数值缩放到整个工作范围内，具体为 0 到 1。光谱波长以 μm 单位表示，而发射量子产率 η_{yield} （公式 S4）和效率 η_{opt} （公式 S1）分别定义为输出 (N_{Emi} 和 P_{out}) 与输入 (N_{Abs} 和 P_{in}) 的比值。该模型中考虑的分类分类器基于制造工艺，包括：i) 光学中心类型，ii) 材料主体类型，iii) 材料主体化学成分，以及 iv) 加工方法。这些分类器的类别在表 1 中详细列出。

用于光学特性参数的数值包括：i) 峰吸收波长 (A_p)，ii) 吸收光谱带的最低波长值 (A_{min})，iii) 吸收光谱带的最高波长值 (A_{max})，iv) 峰发射波长值 (E_p)，v) 发射光谱带的最低波长值 (E_{min})，vi) 发射光谱带的最高波长值 (E_{max})，以及 vii) 绝对发射量子产率 (η_{yield})。为了说明每个实验参数的物理意义，图 1c 说明了具有最大实验值 η_{opt} [42] 的材料的吸收和发射光谱。为了深入了解数据集中多个属性之间的关系，我们对 19 个特征进行了交叉相关分析，如图 1d 所示。总共，对于一个对应于 LSC 光学效率的输出，有 19 个输入特征（属性），从而产生总共 31 个描述符。数据集特征的最终结构可以在补充信息中的图 S1 和图 1e 中找到。这种分析是一种有价值的工具，用于识别数据集中特征之间的关系，即使它们不是线性相关的，因为它可以揭示是否

表1
分类器的类别。来自[41]。

光学中心 type	材料宿主 type	材料宿主化学 成分	处理 方法
量子点	聚合物	PMMA	波导
有机染料	混合	SEBS	电影
碳点	解决方案	PDMS	Bulk
铜系元素	其他	PVP	解决方案
聚合物		聚氨酯	纤维
其他		t-U(5000)	其他
		d-U(600)	
		其他	

PMMA = 聚甲基丙烯酸甲酯；SEBS = 苯乙烯-乙烯/丁烯-苯乙烯嵌段共聚物；PDMS = 聚二甲基硅氧烷；PVP = 聚乙烯吡咯烷酮；t-U(5000) = 三脲基硅有机-无机杂化材料；d-U(600) = 二脲基硅有机-无机杂化材料。

一个或多个属性与其他属性相关联。

有机分子和复合材料如染料、CDs和QDs具有斯托克斯位移（吸收峰和发射峰之间的能量差）约为 $4,200 \pm 3,400 \text{ cm}^{-1}$ （基于表S1的数据）。另一方面，基于镧系元素（Ln）（在表S1中识别为光学中心类型：Ln）的化合物表现出更大的斯托克斯位移，约为 $13,500 \pm 4,800 \text{ cm}^{-1}$ ，通常称为伪斯托克斯位移 [43,44]，因为这些化合物的光物理过程涉及两个中心（一个用于吸收，一个用于发射）。对于基于镧系元素的化合物，吸收发生在有机配体上，通常在紫外光谱区域，而发射来自可见到红外光谱区域的镧系离子。这个过程称为天线效应，其中配体和镧系离子之间的分子内能量转移起着基本作用 [44,45]。

结果表明光学特征之间存在强相关性（图1e中的条目13–19），特别是在 E_{max} （图1e中的条目18）、 E_p （图1e中的条目16）和 A_{max} （图1e中的条目15）之间。这些发现并不令人意外，因为LSCs中的发射和吸收波长与所使用的发光材料的特性密切相关。发射或吸收光谱带通常可以通过高斯带组合来表征。因此，发射带内的 E_{max} 和 E_p 之间存在相关性。然而， η_{yield} 是一个例外，它与所有其他特征都表现出弱相关性，无论材料或光学特性如何。这突出了使用ANN等模型来预测LSCs的 η_{opt} （与 η_{yield} 成正比，见公式S3）的非线性关系的重要性。

2.3. 算法

为了评估算法处理非平衡输入挑战的能力，数据集被随机打乱并分为10个相等的部分进行交叉验证。k折交叉验证是一种重采样方法，可以减少模型的偏差，考虑到 $k = 10$ 已被证明在估计偏差和预测误差[46]方面表现良好。然后使用保留样本对具有优化超参数的最佳方法进行测试。如前所述，保留样本在训练或验证过程中未被使用，仅用于评估最终模型的性能，并从原始数据集中提取，对应于我们中的一些人先前发表的一些值，以确保对与实验测量相关的参数和误差有深入的了解。这一步对于确保模型能够在完全未见过的数据上表现良好且不会偏向训练或验证数据至关重要。

超参数优化在交叉验证阶段进行，以选择具有最佳超参数的最佳模型。此优化的目标是使用小批量梯度下降优化算法选择最佳超参数，其描述如下[47]：

$$\theta_{i+1} = \theta_i - \alpha \nabla_{\theta} J(\theta; x^{(i:n)}, y^{(i:n)}) \quad (2)$$

在 α 是学习率， $J(\cdot)$ 是代价函数，而 θ 是要优化的参数。值得注意的是，这些参数不是从数据中学习到，而是在训练模型之前设置的，例如隐藏层的数量、每层的神经元数量和学习率。相同的优化算法也用于训练过程中，其中权重的初始值 $w_{\text{in}}^{(n)}$ 是随机设置的。只有在选择了最佳性能的特征并对模型进行了完全优化之后，才使用 82.8 % 的数据集进行训练，并在剩余的保留测试集（18.2 %）上进行测试。

在超参数优化和训练过程中，最佳参数是使用输出值与LSC光学效率报告值之间的均方误差估计的，该均方误差被视为成本函数。LSC估计的最终精度是使用均方误差（MSE）、平均绝对误差（MAE）和

确定系数（ R^2 ）统计量，定义为[48]：

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \quad (3)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i| \quad (4)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n \left(Y_i - \frac{1}{n} \sum_{i=1}^n Y_i \right)^2} \quad (5)$$

其中 n 是样本点的数量， $\hat{Y}$ 是 LSC 估计值，而 Y 是相应的测量/报告值。所采用的程序的说明性工作流程如图 2a 所示。优化的 ANN（如图 2b 所示）有 19 个输入神经元，第一隐藏层有 97 个神经元，第二隐藏层有 19 个神经元，以及 1 个输出神经元，学习率为 0.001。

第二隐藏层由19个神经元组成，该层的每个神经元也接收来自前一隐藏层（隐藏层1）所有神经元输入，并使用与第一隐藏层相同的激活函数。在超参数优化和k折测试后，除了保留样本外，完整数据集被用于训练神经网络。该过程涉及将输入数据输入网络，并调整权重以最小化网络输出与实际输出之间的误差。训练过程在以下任一条件满足时停止：网络在验证集上的性能不再改进，且成本函数误差小于0.0001（回想一下，报告的 η_{opt} 值的典型实验精度为0.001），或者迭代次数达到预定义值，在本例中为2.5亿次。

图3a说明了训练过程中成本函数值的演变。当最大迭代次数接近时，误差改进变得较小，每 10^5 次迭代改进小于 10^{-9} 。

完成培训后，我们通过创建散点图比较了预测的 η_{opt} 值与实际值，如图 3b 所示。我们的 ANN 模型在预测 η_{opt} 方面被证明具有高度准确性，这从与该参数测量相关的实验不确定性相比时 $MSE = 5.5 \times 10^{-3}$ 的低值得到证实。该模型在预测高值方面也表现出鲁棒性。此外，图 3b 中的线性拟合，斜率为 1.0027 ± 0.0068 ($R^2 = 0.997$)，几乎与 $y = x$ 趋势一致，表明偏差很小。此外，值得注意的是，预测准确性最差的数据点往往集中在 10 % 左右。这可以归因于原始数据集的潜在错误分类或可能影响报告测量的实验异常/错误。随着异常值的数量减少，对最终结果的整体影响很小，因此已决定不采取任何进一步行动或数据集截断。

3. 结果与讨论

一旦人工神经网络（ANN）经过训练和评估，关键在于在新数据集上验证其性能，以确保其鲁棒性和泛化到未见数据的能力。在本研究中，我们利用保留测试数据集来评估模型的泛化能力，结果如图4所示。表2总结了模型在保留测试和10折交叉验证平均值之间的性能指标。

根据衡量模型性能的三个指标，我们的模型已达到极高的准确率。总之，尽管我们的数据集相对较小，这是由于可获得的报告值稀缺所致，我们可以自信地声明，我们的模型准确预测了所有报告的 η_{opt} 值，其不确定性远小于




图 2。 (a) 具有 2 个隐藏层的 ANN 结构，输入层 (i) 有 19 个神经元，第一个隐藏层 (h₁) 有 97 个神经元，第二个隐藏层 (h₂) 有 19 个神经元，输出层 (o) 有 1 个神经元。 b) 描述预测 LSCs 光学效率所使用流程的工作流。




图 3。 A) 训练过程中的 MSE 进化。 b) 训练后和训练数据集中预测的 η_{opt} 作为测量值的函数。




图 4。 ANN 模型和真实值对滞留数据集中 η_{opt} 参数的估计。参见表 S2 了解滞留测试集中每个组件的更多信息。插图显示了真实值和估计值之间的偏差 ($\Delta\eta_{opt}$)。

实验表征 LSC 时通常遇到的情况。这项研究代表了首次应用机器学习方法预测 LSC 性能，这使得与其他方法建立基准比较变得具有挑战性。

滞留测试集涉及广泛的参数值，导致 η_{opt} 值可能变化超过 270 倍。此外，ANN 模型通过准确预测 η_{opt} 在同一类化合物、主体系统中的表现，展现了卓越的鲁棒性

材料，并且具有相似的吸收特征，但发射中心所用的 Ln 离子类型不同。例如，Tb³⁺-β-二酮四配位配合物 Q[Tb(tta)₄]，其中 Q = 1-丁基-3-[3-(三甲氧基硅基)丙基]咪唑鎓 (表 S2 中的第 3 条目) [49]，由一个具有四个等价配位配体的配位化合物和外部配位层中的抗衡离子组成以平衡电荷。基于该配合物的 LSC 呈现 $\eta_{opt} = 0.27\%$ ，而含有 Eu³⁺-β-二酮三配合物 [Eu(hfac)₃•DPEPO] 的 LSC，其中 hfac = 六氟乙酰丙酮

表 2
ANN 模型的性能指标。交叉验证结果的 uncertainty 值被考虑为均值的 2 倍标准差 (2σ)。

性能指标	10折交叉验证	保持测试
R ²	0.96893 ± 0.09722	0.99955
MSE	0.0055 ± 0.0207	1.2 × 10 ⁻⁵
MAE	0.2230 ± 0.5750	0.0017

和DPEPO = 双(2-(二苯基膦基)苯基)醚氧化物 (表S2中的第42条目), 具有 $\eta_{opt} = 60\%$ [50]。这两个配合物都从β-二酮配体共享相似的吸收特征, 并且都存在于同一材料 (PMMA) 中。然而, ANN模型可以在小于1%的误差范围内区分它们。

另一个例子涉及具有相似光学特性但不同材料特性的 LSCs 的不同制备方法。例如, 考虑基于罗丹明 B 的碳点 (CDs) (表 S2 中的条目 #25) [51] 和基于柠檬酸的碳点 (CDs) (表 S2 中的条目 #35) [52]。尽管在峰值位置方面具有相似的光学特性, 但它们是使用不同的方法制备的。基于罗丹明的碳点以薄膜形式在 PVP 中处理, 而基于柠檬酸的碳点以块状材料形式在 PMMA 中处理。它们的 η_{opt} 值分别从 4.8% 到 9.3%, 这表明 ANN 模型还捕捉了实验条件的影响。这突出了模型在主材料和处理方法改变时推断 η_{opt} 的能力。这些比较例子验证了此处开发的 ANN 模型在新型 LSCs 设计中的实用性。

本研究中我们预测的有效性可归因于输入特征的精心选择, 如图S1所示。这些特征与输出变量 η_{opt} 呈现非线性关系, 突显了光谱特性及材料组成作为描述性因素对LSCs光转换效率的重要性。

4. 结论

光谱转换器件是一种创新技术, 具有显著提升太阳能转换效率的潜力, 但由于多种因素对其性能的影响, 其设计和优化具有挑战性。然而, 确定此类器件的特性需要相当的时间和精力。为应对这一挑战, 我们开发了一个ANN模型作为预测光转换效率(η_{opt})的工具, 考虑了发光太阳能集中器 (LSCs) 的组成、结构和光学表征特征。我们使用来自公共库的236个样本数据集评估了该模型, 结果表明ANN模型准确预测了 η_{opt} 值。该模型使用总数据集的~82 %进行训练, 其余的~18%用于验证。验证结果表明, ANN可以以均方误差为 1.2×10^{-5} 预测 η_{opt} 值, 展现出高精度和优异的泛化能力。本研究的意义在于其能够加速该领域的研究, 并为开发更高效和可持续的太阳能技术做出贡献。训练好的网络参数已准备好供该领域的利益相关者使用 (补充信息)。通过使用ANN对各种参数与光谱转换器性能之间的复杂关系进行建模, 我们可以在无需大量实验测量的情况下预测新器件的效率。因此, 这种方法有潜力加速高效系统的开发, 并助力向可持续能源未来转型。

作者贡献

RASF 和 PSA 参与了研究计划确定、所有数据获取、数据分析、结果讨论和文稿撰写。

SFHC 参与了数据获取、数据分析和文稿撰写。ANCN 参与了文稿修改和光谱分析。PSA 和 LMSD 定义了 ANN。

利益冲突声明

作者声明他们没有已知的利益冲突或个人关系可能影响本文中报告的工作。

致谢

这项工作由葡萄牙2020计划通过欧洲区域发展基金 (ERDF) 在 CENTRO2020框架内资助, 在项目PLANETa、CENTRO - 01-0247-FEDER-181242的范围内, 以及CICECO-Aveiro材料研究所 (UIDB/50011/2020 & UIDP/50011/2020)、电信研究所 (FCT Ref. UIDB/50008/2020)、SOLPOWINS - 可持续建筑用太阳能智能窗户 (PTDC/CTM-REF/ 4304/2020) 的范围内, 由国家资金通过 FCT/MEC资助, 并在适当情况下由FEDER在PT2020伙伴关系框架下通过欧洲区域发展基金 (ERDF) 在运营竞争力和国际化计划 (POCI) 的范围内共同资助。SFHC和LMSD感谢FCT (2022.03740。CEECIND和UI/BD/ 153491/2022, 分别), PSA感谢CMU葡萄牙的流动资助 (CMU-P, 管理2020)。ANCN希望感谢Shape of Water项目 (PTDC/NAN- PRO/3881/2020) 的支持, 该项目由葡萄牙资金通过 FCT/MEC (PIDDAC) 资助。T. Galvão (CICECO) 因关于ANN的有益讨论而受到感谢。

附录 A. 补充数据

本文的补充数据可在 <https://doi.org/10.1016/j.solener.2023.112290> 在线获取。

参考文献

[1] Directive 2018/844 of the European Parliament and of the Council of 30 May 2018 amending Directive 2010/31/EU on the energy performance of buildings and Directive 2012/27/EU on energy efficiency. 2018: Brussels, Belgium.

[2] Pacheco-Torgal, F., Nanotechnology in eco-efficient construction. 2nd edition ed. 2019: Woodhead Publishing.

[3] D. D'Agostino, L. Mazzarella, What is a nearly zero energy building? Overview, implementation and comparison of definitions, J. Build. Eng. 21 (2019) 200–212.

[4] E. Kabir, P. Kumar, S. Kumar, A.A. Adelodun, K.H. Kim, Solar energy: potential and future prospects, Renew. Sust. Energy Rev. 82 (2018) 894–900.

[5] B. McKenna, R.C. Evans, Towards efficient spectral converters through materials design for luminescent solar devices, Adv. Mater. 29 (28) (2017) 1606491.

[6] F. Mateen, M.A. Saeed, J.W. Shim, S.K. Hong, Indoor/outdoor light-harvesting by coupling low-cost organic solar cell with a luminescent solar concentrator, Sol. Energy 207 (2020) 379–387.

[7] F. Meinardi, H. McDaniel, F. Carulli, A. Colombo, K.A. Velizhanin, N.S. Makarov, R. Simonutti, V.I. Klimov, S. Brovelli, Highly efficient large-area colourless luminescent solar concentrators using heavy-metal-free colloidal quantum dots, Nat. Nanotechnol. 10 (10) (2015) 878–885.

[8] B.S. Richards, I.A. Howard, Luminescent solar concentrators for building integrated photovoltaics: opportunities and challenges, Energy Environ. Sci. 16 (8) (2023) 3214–3239.

[9] F. Meinardi, F. Bruni, S. Brovelli, Luminescent solar concentrators for building-integrated photovoltaics, Nat. Rev. Mater. 2 (12) (2017) 17072.

[10] D.E. Smith, M.D. Hughes, D.A. Borca-Tasciuc, Towards a standard approach for annual energy production of concentrator-based building-integrated photovoltaics, Renew. Energy 186 (2022) 469–485.

[11] R.A.S. Ferreira, S.F.H. Correia, A. Monguzzi, X. Liu, F. Meinardi, Spectral converters for photovoltaics – what's ahead, Mater. Today 33 (2020) 105–121.

[12] Y. Hu, M.J. Buehler, Deep language models for interpretative and predictive materials science, APL Mach. Learn 1 (2023) 010901.

[13] M. Srivastava, A.R. Hering, Y. An, J.P. Correa-Baena, M.S. Leite, Machine learning enables prediction of halide perovskites' optical behavior with >90% accuracy, ACS Energy Lett. 8 (4) (2023) 1716–1722.

[14] H. Jaeger, H. Haas, Harnessing nonlinearity: predicting chaotic systems and saving energy in wireless communication, Science 304 (5667) (2004) 78–80.

- [15] P. Newbold, ARIMA model-building and the time-series analysis approach to forecasting, *J. Forecasting* 2 (1) (1983) 23–35.
- [16] O.A. Montesinos López, A. Montesinos López, J. Crossa, Fundamentals of artificial neural networks and deep learning in.). Multivariate Statistical Machine Learning Methods for Genomic Prediction, Springer, Cham, Switzerland, 2022.
- [17] E. Karatepe, M. Boztepe, M. Colak, Neural network based solar cell model, *Energy Convers. Manage.* 47 (9–10) (2006) 1159–1178.
- [18] G.X. Zhang, Y.J. Song, W. Zhao, H.W. An, J.J. Wang, Machine learning-facilitated multiscale imaging for energy materials, *Cell. Rep. Phys. Sci.* 3 (9) (2022), 101008.
- [19] J.Q. Mai, T. Lu, P.C. Xu, Z.H. Lian, M.J. Li, W.C. Lu, Predicting the maximum absorption wavelength of azo dyes using an interpretable machine learning strategy, *Dyes Pigm.* 206 (2022), 110647.
- [20] J.F. Joung, M. Han, J. Hwang, M. Jeong, D.H. Choi, S. Park, Deep learning optical spectroscopy based on experimental database: potential applications to molecular design, *JACS Au* 1 (4) (2021) 427–438.
- [21] M. Fu, T. Mrziglod, W.L. Luan, S.T. Tu, L. Mleczo, Neural network modeling and simulation of the synthesis of CuInS₂/ZnS quantum dots, *Eng. Rep.* 2 (2) (2020).
- [22] H. Hernandez-Noyola, D.H. Potterveld, R.J. Holt, S.B. Darling, Optimizing luminescent solar concentrator design, *Energy Environ. Sci.* 5 (2) (2012) 5798.
- [23] S. Quesada-Ruiz, A. Linares-Rodriguez, J.A. Ruiz-Arias, D. Pozo-Vazquez, J. Tovar-Pescador, An advanced ANN-based method to estimate hourly solar radiation from multi-spectral MSG imagery, *Sol. Energy* 115 (2015) 494–504.
- [24] P. Malik, A. Gehlot, R. Singh, L.R. Gupta, A.K. Thakur, A review on ANN based model for solar radiation and wind speed prediction with real-time data, *Arch. Comput. Method.* e. 29 (5) (2022) 3183–3201.
- [25] N. Tomar, G. Rani, V.S. Dhaka, P.K. Surolia, Role of artificial neural networks in predicting design and efficiency of dye sensitized solar cells, *Int. J. Energy Res.* 46 (9) (2022) 11556–11573.
- [26] B. Ameen, H. Balzter, C. Jarvis, J. Wheeler, Modelling hourly global horizontal irradiance from satellite-derived datasets and climate variables as new inputs with artificial neural networks, *Energies* 12 (1) (2019) 148.
- [27] A. Aallouche, H. Ouadi, Online fault detection and identification for an isolated PV system using ANN, *IFAC-PapersOnline* 55 (12) (2022) 468–475.
- [28] D. Korkmaz, H. Acikgoz, An efficient fault classification method in solar photovoltaic modules using transfer learning and multi-scale convolutional neural network, *Eng. Appl. Artif. Intel.* 113 (2022), 104959.
- [29] J.M. Ripalda, J. Buencuerpo, I. Garcia, Solar cell designs by maximizing energy production based on machine learning clustering of spectral variations, *Nat. Commun.* 9 (2018) 5126.
- [30] S. Chugh, A. Gulistan, S. Ghosh, B.M.A. Rahman, Machine learning approach for computing optical properties of a photonic crystal fiber, *Opt. Express* 27 (25) (2019) 36414–36425.
- [31] C.P. Yu, H.C. Chang, Applications of the finite difference mode solution method to photonic crystal structures, *Opt. Quant. Electron.* 36 (1–3) (2004) 145–163.
- [32] A. Cucinotta, S. Selleri, L. Vincetti, M. Zoboli, Holey fiber analysis through the finite-element method, *IEEE Photon. Tech. L.* 14 (11) (2002) 1530–1532.
- [33] S.G. Johnson, J.D. Joannopoulos, Block-iterative frequency-domain methods for Maxwell's equations in a planewave basis, *Opt. Express* 8 (3) (2001) 173–190.
- [34] R.A. Norton, R. Scheichl, Planewave expansion methods for photonic crystal fibres, *Appl. Numer. Math.* 63 (2013) 88–104.
- [35] S.Y. Shi, C.H. Chen, D.W. Prather, Plane-wave expansion method for calculating band structure of photonic crystal slabs with perfectly matched layers, *J. Opt. Soc. Am. a.* 21 (9) (2004) 1769–1775.
- [36] V. Lo Brano, S. Guarino, A. Buscemi, M. Bonomolo, Development of neural network prediction models for the energy producibility of a parabolic dish: a comparison with the analytical approach, *Energies* 15 (24) (2022) 9298.
- [37] E. Viera-Martin, J.F. Gomez-Aguilar, J.E. Solis-Perez, J.A. Hernandez-Perez, R. F. Escobar-Jimenez, Artificial neural networks: a practical review of applications involving fractional calculus, *Eur. Phys. J. Spec. Top.* 231 (10) (2022) 2059–2095.
- [38] S. Narayan, The generalized sigmoid activation function: Competitive supervised learning, *Inform. Sciences* 99 (1–2) (1997) 69–82.
- [39] D.E. Rumelhart, G.E. Hinton, R.J. Williams, Learning representations by back-propagating errors, *Nature* 323 (6088) (1986) 533–536.
- [40] P.O.J. Scherer, Computational physics - simulation of classical and quantum systems, Springer, Cham, 2017.
- [41] Ferreira, R.A.S., Correia, S.F.H., Geogieva, P., Fu, L., Antunes, M., André, P.S., 2023. *Scientific Data*, 10.1038/s41597-023-02827-3.
- [42] S.F.H. Correia, A.R. Frias, L.S. Fu, R. Rondao, E. Pecoraro, S.J.L. Ribeiro, P. S. Andre, R.A.S. Ferreira, L.D. Carlos, Large-area tunable visible-to-near-infrared luminescent solar concentrators, *Adv. Sustainable Syst.* 2 (6) (2018) 1800002.
- [43] D. Parker, J.D. Fradgley, M. Delbianco, M. Starck, J.W. Walton, J.M. Zwier, Comparative analysis of lanthanide excited state quenching by electronic energy and electron transfer processes, *Faraday Discuss.* 234 (2022) 159–174.
- [44] J.F.C.B. Ramalho, Carneiro Neto, A.N., Carlos, L.D., André, P.S., Ferreira, R.A.S., *Lanthanides for the new generation of optical sensing and Internet of Things*, in: J.-C. Bünzli, V.K. Pecharsky (Eds.), Handbook on the Physics and Chemistry of Rare Earths, Elsevier Science, B. V., Amsterdam, 2022, pp. 31–128.
- [45] A.N. Carneiro Neto, E.E.S. Teotonio, G.F. de Sá, H.F. Brito, J. Legendziewicz, L. D. Carlos, M.C.F.C. Felinto, P. Gawryszewska, R.T. Moura, R.L. Longo, W. M. Faustino, O.L. Malta, Chapter 310 - Modeling intramolecular energy transfer in lanthanide chelates: A critical review and recent advances, in: J.-C.-G. Bünzli, V. K. Pecharsky (Eds.), Handbook on the Physics and Chemistry of Rare Earths, Elsevier, 2019, pp. 55–162.
- [46] A.M. Molinaro, R. Simon, R.M. Pfeiffer, Prediction error estimation: a comparison of resampling methods, *Bioinformatics* 21 (15) (2005) 3301–3307.
- [47] R. Dwivedi, V.K. Srivastava, Fundamental optimization methods for machine learning, in: T. Goswami, G.R. Sinha (Eds.), Statistical Modeling in Machine Learning, Academic Press, 2023, pp. 227–247.
- [48] D. Chicco, M.J. Warrens, G. Jurman, The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation, *PeerJ Comput. Sci.* 7 (2021) e623.
- [49] A.R. Frias, M.A. Cardoso, A.R.N. Bastos, S.F.H. Correia, P.S. Andre, L.D. Carlos, V. D. Bermudez, R.A.S. Ferreira, Transparent luminescent solar concentrators using Ln³⁺-based ionosilicas towards photovoltaic windows, *Energies* 12 (3) (2019) 451.
- [50] L.R. Wilson, B.C. Rowan, N. Robertson, O. Moudam, A.C. Jones, B.S. Richards, Characterization and reduction of reabsorption losses in luminescent solar concentrators, *Appl. Optics* 49 (9) (2010) 1651–1661.
- [51] X. Gong, S.Y. Zheng, X.J. Zhao, A. Vomiero, Engineering high-emissive silicon-doped carbon nanodots towards efficient large-area luminescent solar concentrators, *Nano Energy* 101 (2022), 107617.
- [52] L.P. Gao, C.L. Wang, S.H. Xu, P.F. Xia, F. Liu, H.C. Sun, Z.Y. Wang, C.G. Lu, Y. P. Cui, Free radical-resistant carbon dots for bulky luminescent solar concentrators with high optical efficiency, *ACS Appl. Nano Mater.* 5 (6) (2022) 7850–7857.