

原创文章

应用于阿拉伯国家光伏系统中的脉冲神经网络与传统人工神经网络的太阳辐射预测

Bahgat Ayasi^{1,7}  · 伊阿古 X. 瓦兹奎兹²  · 穆罕默德·萨利赫³  · Angel M. 加西亚·维科^{4,5}  · 克里斯托巴尔·J·卡莫纳 

收到：2024年9月22日 / 接受：2025年2月3日 / 网络发布：2025年3月1日© 作者（们），在 Springer-Verlag London Ltd. (Springer Nature 2025年部分) 的独家许可下

摘要

将光伏（PV）系统并入电网日益关键，特别是在阳光充足的阿拉伯国家。本研究介绍了一种使用脉冲神经网络（SNNs）预测太阳辐射的新方法。我们利用Lava框架开发和比较单变量和多变量场景中的不同神经网络架构。我们的研究表明，SNNs在建模和预测方面的性能与传统人工神经网络（ANNs）相当。具体而言，当使用卷积神经网络（CNN）架构对多变量时间序列数据建模时，SNNs的误差率与其ANN对应物的误差率相似。然而，SNNs在能效方面具有显著优势，在Loihi神经形态芯片和传统GPU上使用SLAYER算法的直接训练方法估算时，效率大约高9倍。此外，在Loihi和GPU上使用引导算法的转换训练方法，效率提升约7至8倍。本研究通过引入SNNs作为传统ANNs的能效替代方案，为阿拉伯地区的PV运行优化做出了贡献，用于太阳辐射预测。它通过提供一种强大的模型来高效预测太阳能输出，同时最小化计算能耗足迹，与全球可持续发展目标保持一致。尽管本研究中的数据来自阿拉伯地区的来源，但由于其普遍相关性，方法和研究结果适用于其他地区。我们研究结果的实际意义支持可持续能源基础设施的扩展，强调了创新预测模型在提高可再生能源可靠性和效率方面的战略重要性。

关键词 神经网络（SNN） · 时间序列预测 · 神经形态计算 · 太阳能预测 · 电力效率 · 光伏（PV）系统

1 引言

巴勒斯坦拥有丰富的太阳能潜力，年日照时数约为3,000小时，平均太阳辐射量为5.4 kWh/m²/天。这使得光伏（PV）系统成为实现能源独立和促进社会经济发展的战略能源解决方案。同时，这也符合可持续发展目标7（SDG 7），旨在确保人人享有负担得起、可靠、可持续和现代化的能源。先前研究表明，在巴勒斯坦，光伏系统具有经济可行性和技术优势，包括减少电网损耗、提高电压水平以及降低对进口能源的依赖。



此外，部署光伏系统通过降低运营成本和减少对昂贵进口能源的依赖，有助于经济稳定。准确的太阳能预测能够优化投资，确保光伏设施被战略性地部署以最大化回报，从而刺激当地经济增长，并在制造业、安装和维护领域创造就业机会。此外，通过可靠的太阳能电力提升能源获取能力，能够通过改善生活水平和支持偏远及服务不足地区的可持续基础设施发展，促进社会发展。

通过先进的预测方法（如SNNs和神经形态计算）优化光伏系统效率，可以显著影响该地区的能源经济。通过减少AI模型的计算能耗，更多的太阳能发电量可以用于公共使用，从而提高光伏投资的净现值（NPV），在巴勒斯坦地区，该值介于每千瓦187至2,811美元之间 [7]。此外，虽然AI为科学进步提供了巨大机遇，但由于数据中心和存储设施支持AI运行的高能耗，它也带来了重大挑战。这种相当大的能源消耗引发了关于在最大程度发挥AI效益的同时最小化环境影响的关键问题。我们的研究通过使用SNNs保持太阳辐射预测的准确性和效率，并强调开发节能AI模型来解决这些问题。这种双重方法确保在可再生能源系统中部署AI能够积极促进可持续发展目标，而不会增加额外的环境负担。此外，高效的计算方法通过促进能源自主和可持续基础设施发展，支持了社会政治挑战 [5, 6, 8–12]。增强太阳辐射预测对于优化光伏系统效率和支持阿拉伯国家的能源独立至关重要 [13–15]。本研究专注于小时级预测，这对于实时能源管理和电网稳定性至关重要。研究表明，ARIMA等模型在改进太阳辐射预测方面的有效性，从而有助于将太阳能整合到国家电网中 [16]。此外，解决诸如并网光伏系统功率因数降低等挑战需要综合策略来提高可再生能源的可靠性和效率 [17]。

能源生产中的时间序列预测已从传统的统计方法（如ARIMA[18, 19]）发展到深度学习技术（如LSTM和CNNs），这些技术提供了更高的预测精度和更好的时间模式识别能力 [20–23]。然而，这些深度学习模型虽然准确，但通常计算密集且消耗大量能源，增加了AI运营的整体能源足迹 [11, 24, 25]。这在像阿拉伯国家这样的地区构成挑战，因为这些地区高效利用太阳能对于社会经济发展至关重要。

将SNNs集成到可再生能源领域为阿拉伯地区优化能源管理提供了机会。SNNs具有高度节能性，模拟大脑的极低能耗，这对于光伏系统至关重要，因为计算能耗会影响整体效率 [25, 26]。通过减少计算能耗，SNNs最大化可用于社区的能源输出，并与全球可持续发展目标保持一致。此外，SNNs在建模复杂非线性系统方面表现出色，使其成为精确太阳能预测的理想选择，从而促进能源独立和环境保护 [26–36]。

在本研究中，我们通过利用神经形态计算原理，并使用 Lava 框架¹ [37]，——一个用于脑启发计算的开放源码软件平台——以及 SNNs，实现了一种新的太阳辐射预报方法。我们开发并比较了单变量和多变量时间序列模型中的不同网络架构，有效地利用了 SNNs 的效率和可扩展性，代表了可再生能源预报方法的重要进步。

本研究探讨了各种SNN架构和训练策略在光伏预测中的潜力，并将它们的性能与传统ANNs进行比较。通过使用多样化的数据集和学习算法评估这些模型，我们旨在了解预测精度与计算效率之间的权衡 [38]。我们的方法论展示了像SNN这样的节能预测算法在

¹ https://lava-nc.org/lava/notebooks/in_depth/tutorial01_安装_lava.html.

提高光伏系统效率和可持续性方面的显著优势，优化能源生产并减少对化石燃料的依赖，从而支持阿拉伯地区的经济发展和可持续性。

本文结构如下：第2节回顾相关工作，第3节描述方法论，第4节介绍实验设置，第5节讨论结果，第6节总结未来研究方向和启示。

2 相关工作

本节讨论与本研究相关的主要概念，重点关注时间序列预测和SNNs应用。

2.1 时间序列预测

时间序列预测已取得显著发展，传统统计方法如ARIMA模型在建模时序数据方面具有基础性作用 [39]。ARIMA模型因其能够捕捉平稳时间序列中的各种模式而被广泛应用。传统ARIMA模型的扩展已被探索以提升预测精度。例如，[40] 提出使用遗传算法进行ARMA模型估计以预测天然气消耗，展示了比经典ARMA模型更好的预测性能。其他方法如灰色预测模型也被应用于能源需求预测。[41] 提出使用遗传算法和粒子群优化等优化算法改进灰色预测模型，实现了更准确的能源需求预测。

机器学习和深度学习技术的出现显著提高了预测精度，特别是在处理非线性复杂模式方面。由 [42] 引入的长短期记忆（LSTM）单元的循环神经网络（RNN）有效解决了梯度消失问题，能够捕捉数据中的长期依赖关系。由于其增强的预测能力，这些模型在各种场景中已经超越了传统方法如ARIMA。[42–44]。

先进的深度学习模型已被应用于环境预测任务。[45] 使用深度学习网络（如CNN和LSTM）结合时空聚类，解决了多小时和多站点的空气质量指数预测问题，提高了预测精度。然而，这些复杂的模型通常需要大量的计算资源，这可能不符合节能目标。

在光伏发电预测的背景下，结合深度学习模型的混合方法显示出有前景的结果。[38] 提出了一种结合深度时间序列聚类和基于特征注意力的深度预测的混合方法，显著降低了预测误差。类似地，[46] 强调了混合方法在准确预测光伏输出的有效性，尽管这些模型通常需要先进的计算资源。

进一步研究，如 [47–51]，和 [52]，已探索了多种用于可再生能源预测的机器学习和深度学习方法，突出了预测能力增强与计算需求增加之间的权衡。

这些研究表明了可再生能源预测领域的发展趋势，展示了神经网络和深度学习技术的日益重视。然而，这些高级模型的显著计算需求与光伏系统的低能耗理念相矛盾。这突显了SNN在提供相当预测能力的同时，能以更低能耗和硬件需求带来显著优势的关键领域。

随后，我们的ANNs和SNNs显示的MAE、RMSE和nRMSE值接近文献中报告的数值，与 [38, 53–56] 和 [57] 强调的太阳能辐射预测中的挑战和创新相符。这些研究共同强调了提高可再生能源系统准确性和计算效率的目标，为我们研究确立了基准，我们期望达到并贡献于该基准。

2.2 爆发式神经网络 (SNNs)

SNNs作为神经网络的第三代模型，以其模拟生物神经网络时间动态的能力而著称 [27]。与早期的神经网络模型不同，SNNs利用离散事件或“尖峰”在神经元之间进行通信，这些事件发生在神经元的膜电位超过特定阈值时。

神经元传递的信息内容编码在爆发脉冲的数量和爆发时间中，而非每个脉冲的形式。这种爆发脉冲序列由以规则或不规则间隔发生的电脉冲组成，在神经通信中起着关键作用 [58]。

它们被定义为突触后电位 (PSPs)，即反映突触后神经元膜电位变化的时变函数。突触后神经元对传入脉冲的响应受这些PSPs的调节，而PSPs可以是兴奋性的或抑制性的，这取决于突触的类型 [59]。PSPs对于信号在突触间的传递至关重要，并数学建模为等式(1)：

$$PSP(t) = \frac{t}{\tau} e^{(1-\frac{t}{\tau})} \quad (1)$$

其中 τ 表示表征电位衰减的时间常数 [60]。或者，输入脉冲对突触后神经元膜电位的影响也可以用等式(2)表示：

$$V_i(t) - V_{\text{rest}} = \delta i_j(t) \quad (2)$$

其中 $V_i(t)$ 表示时间 t 时的膜电位， V_{rest} 是静息膜电位，而 $\delta i_j(t)$ 表示由突触前神经元 j [59] 产生的突触后电位。

2.2.1 SNN 中的主要神经元模型

- 漏电积分点火 (LIF) 模型：这是由公式 (3) 描述的最简单的神经元模型之一 [59]：

$$\tau_m \frac{dV(t)}{dt} = -[V(t) - V_{\text{rest}}] + R \cdot I(t) \quad (3)$$

其中 $V(t)$ 是膜电位， τ_m 是膜时间常数， V_{rest} 是静息电位， R 是膜电阻， $I(t)$ 是输入电流。当 $V(t)$ 达到给定阈值时，神经元会点火并将 $V(t)$ 重置为 V_{rest} 。

- Izhikevich 神经元模型：为模拟受公式 (4) 和 (5) 控制的神经元点火模式提供了计算高效的框架 [61]，：

$$\frac{dV}{dt} = 0.04V^2 + 5V + 140 - U + I \quad (4)$$

$$\frac{dU}{dt} = a(bV - U) \quad (5)$$

其中 V 表示膜电位， U 表示恢复变量， I 表示输入电流， a 、 b 、 c 、 d 是可调参数。当 V 达到 ≥ 30 毫伏时，神经元会放电并重置 V ，如式 (6) 所示：

$$\text{if } V \geq 30 \text{ mV, then } \left\{ \begin{array}{l} V \leftarrow c, \\ U \leftarrow U + d \end{array} \right\} \quad (6)$$

该模型能够高效模拟多种神经元行为。

- Sigma-Delta (RD) LIF神经元模型：基于Lava框架 [37, 62]，具有sigma解码器和delta编码器。delta编码器基于ReLU输出激活，如公式(7)所示：

$$\Delta_t = \begin{cases} x_t - \hat{x}_{t-1} & \text{if } |x_t - \hat{x}_{t-1}| > \theta, \\ 0 & \text{otherwise} \end{cases} \quad (7)$$

其中 x_t 是时间 t 的输入， $\hat{x}_{t-1}$ 是前一个估计值， θ 是阈值。sigma单元根据公式(8)重建输入：

$$\hat{x}_t = \hat{x}_{t-1} + \Delta_t \quad (8)$$

该模型在不增加延迟的情况下降低了计算成本，并支持各种层类型。

- 基于电流 (CUBA) LIF神经元模型：通过将突触电流直接整合到膜电位中简化神经元动力学，用微分公式(9) [37, 63]表示：

$$\tau_m \frac{dV(t)}{dt} = -V(t) + R \cdot I(t) \quad (9)$$

该模型专注于当前输入与电压响应之间的直接关系。

2.2.2 脉冲神经网络中的学习范式

由于脉冲函数不可微，训练脉冲神经网络具有挑战性。我们的研究利用了两种先进方法：

- 使用SLAYER 2.0进行直接训练：SLAYER（时间中的脉冲层误差重新分配） [64] 是一种用于脉冲神经网络的反向传播机制，使用替代梯度来近似脉冲导数。SLAYER 2.0 [37, 65] 支持多种神经元模型，如Sigma-Delta LIF和CUBA-LIF，增强了灵活性和训练效率。
- 使用引导方法进行ANN到SNN的转换：该方法通过迭代调整ANN以更好地模拟SNN输出，从而改进ANN到SNN的转换，实现具有最小性能损失的、高效的低延迟SNN。

这些方法解决了训练挑战，并提高了计算效率和准确性 [64]。其他方法包括通过脉冲时间依赖性可塑性 (STDP) 进行无监督学习，以及结合神经形态和经典计算元素混合方法 [66, 67]。

SNNs 由于其基于脉冲的通信方式而具有能效性，仅在必要时激活处理组件 [27, 58, 59]。它们在涉及时间模式的任务中表现出色，非常适合动态环境，其中精度至关重要。

SNNs 因其适应性而闻名，被应用于信号处理和模式识别。它们在金融预测 [35, 68]，图像识别 [69–73]，以及可再生能源预测 [32, 74, 75] 方面取得了成功。

[76]中的研究表明，使用SLAYER的SNN在单变量时间序列预测中表现出色，实现了低功耗和快速处理，适合边缘设备。他们的发现强调了SNN在保持低计算需求的同时超越基线模型的潜力。

[77] 的最新工作提出了一种基于非线性脉冲机制的模型，用于短期光伏功率预测，采用脉冲神经网络系统。然而，它采用单一网络架构，使用速率编码，并未计算功耗或模型效率。

光伏系统安装量的增加提高了对可靠发电预测的需求。SNNs能够分析复杂的时空数据，提升光伏预测的准确性，并展示其在各个领域的广泛应用。

3 材料与方法

我们的研究主要旨在评估SNNs在预测光伏系统时间序列数据方面的有效性。我们使用了来自国家太阳辐射数据库的两个小时级数据集 [78]。其中一个数据集来自巴勒斯坦的杰宁市（纬度 = 32.45，经度 = 35.3），另一个来自约旦的安曼市（纬度 = 31.97，经度 = 35.94），代表阿拉伯地区。

3.1 神经网络描述

我们的研究旨在通过神经网络提升时间序列预测的能量效率和准确性。我们探索了SNNs与传统ANNs的能力，重点关注利用SNNs独特的神经元动力学及其在时间序列数据分析中实现节能处理的潜在优势。


具体而言，我们的研究评估了各种神经网络模型在预测单变量和多变量时间序列数据方面的有效性，包括LSTMs、MLPs和CNNs。我们在SNNs中采用Sigma-Delta编码[62]，通过SLAYER替代梯度方法直接训练，以处理脉冲的非可微特性。这种方法使我们能够保持数据的时序完整性，这对准确的时间序列预测至关重要。此外，我们使用Bootstrap方法 [37]在ANNs-to-SNNs训练中进行速率编码。这种创新的转换过程最小化了延迟，并在推理过程中保持了高效率，确保ANNs能够利用SNN架构而不会显著损失性能。

这些方法旨在证明 SNN 在实际应用中的可行性，并展示其在能效方面优于传统 ANN，特别是在时间序列分析的场景中。我们以基本配置启动实验，从更简单的网络架构开始。最初，部署了一个包含最少神经元数量的单层网络来确定基准性能。随后，通过为每个模型添加更多层和神经元来系统地增加网络复杂度——最多包含两个各 32 个神经元的隐藏层。这种实证方法确保每个网络配置在增加更多复杂度之前都经过优化，以保证稳定性和性能。

为了补充我们的研究，使用能够捕获时间序列数据长期依赖关系的架构，我们引入了 LSTM 模型。LSTM 网络（如图 1a 所示，详细见表 7）配置了一个包含 32 个单元的单层 LSTM，以有效捕获过去和未来数据点的模式。这种结构提高了网络的预测精度。在 LSTM 层之后，我们的模型包含两个各 32 个神经元的隐藏（密集）层来细化预测。这种 LSTM 配置通过实证方法确定，以平衡训练效率和计算需求，确保在不同数据集上的鲁棒泛化能力。

MLP 和 CNN 模型因其擅长捕捉数据中的时序和空间模式而被选用。MLP 模型（如图 1b 所示，并在表 7 中详细说明）针对本研究进行了优化，包含两个隐藏（密集）层。每个隐藏层配备 32 个神经元，这些神经元是根据我们数据的特点设计的，这些特点包括从时间序列窗口化中提取的三个时间滞后特征。CNN 模型（如图 1c 所示，并在表 7 中详细说明）的结构旨在增强特征提取，包含两个卷积层，每个层有 32 个滤波器、一个展平操作和两个隐藏（密集）层。这种配置有助于精确捕捉局部、位移不变的时序特征，这对时序分析至关重要。

图1 时间序列预测的网络架构概述。a LSTM: 一个32单元层加上两个密集层; b MLP: 两个各含32个神经元的密集层; c CNN: 两个卷积层 (32个滤波器) 后接两个密集层



将数据编码为尖峰对于有效地集成 SNN 至关重要。对于 SNN，我们采用两种方法学：(1) 使用 Sigma-Delta 调制的 SLAYER 直接训练，以及 (2) ANN 到 SNN 的引导转换。Sigma-Delta 调制将实值输入转换为尖峰模式，然后使用 SLAYER 框架进行处理。这种方法能够在尖峰事件不可微分的条件下实现基于梯度的学习，保留输入数据中固有的时序动态性，并提高计算能效。

相反地，这些人工神经网络 (ANNs) 采用传统的速率编码方案进行训练。训练完成后，通过引导方法对这些 ANNs 进行适配，以促进它们转换为脉冲神经网络 (SNNs)。这种策略确保了 ANNs 和 SNNs 在可比条件下运行，从而能够公平地比较它们的准确性和能耗性能。

这些方法论选择与我们的目标一致，即提高时间序列预测的能效和准确性。本研究使用的每种网络架构的配置汇总在表1中。优化的架构和训练方法将在结果部分详细讨论，其中我们将比较不同网络配置的性能结果。

3.2 太阳能辐射预测中SNN的数据编码

SNNs的准确性和效率很大程度上取决于所使用的编码机制 [79]，特别是在太阳能辐射预测的背景下。波动性、噪声以及零值的大量存在是太阳能辐射数据集的特点。因此，选择合适的编码策略以进行有效预测至关重要。本研究考察了四种通过Sigma-Delta LIF和CUBA-LIF神经元实现的编码方案：速率编码、首次脉冲时间 (TTFS)、种群编码和Sigma-Delta编码。我们将确定我们的

表1 网络架构

网络类型	架构	神经元/过滤器
LSTM	三层：一层LSTM层，两层密集层	LSTM层32个单元，密集层32个神经元
MLP	两层密集层	32个神经元 (密集层)
CNN	四层：2个卷积层，两层密集层	32个过滤器 (卷积层)，32个神经元 (密集层)

实验研究中第4节所述数据集最合适的编码方案。该方案将基于其展示卓越性能和实现最佳模型收敛的能力进行选择。我们将针对直接训练和ANN到SNN转换进行此评估，并考虑实验中使用的不同神经元类型。

3.2.1 采用的关键编码方案

- **Sigma-Delta (RD) 编码在SNN中的应用**：整合连续输入之间的差异($\Delta x_t = x_t - x_{t-1}$)，当累积变化总和 (Rt) 与当前变化 (Dxt) 超过阈值时触发尖峰，从而将输入编码为尖峰。这种自适应机制能高效处理时变信号，显著降低能耗。其在神经形态计算中维持高信号质量同时最小化功耗的能力已得到充分验证 [80]。
- **速率编码在SNN中的应用**：通过时间窗口内尖峰的频率编码信息，定义为 $V = \frac{N_{\text{spike}}}{T}$ ，其中 V 是平均放电率， N_{spike} 是尖峰数量，T 是时间窗口。速率编码对对抗性攻击具有鲁棒性，且数据处理能效高，适用于大规模SNN应用 [81]。
- **时间编码**：特别是时间-首脉冲编码 (TTFS) 使用刺激后第一个脉冲的精确时间，由公式(10)给出：

$$t_{\text{spike}} = t_{\text{onset}} + \Delta t, \quad (10)$$

TTFS具有生物学合理性且功耗低，适合快速感官处理。但它面临解码复杂性和对噪声敏感的挑战，影响硬件实现中的鲁棒性 [59, 82]。

- **群体编码**：使用神经元群体的集体活动编码信息，表示为公式(11)：

$$R = \sum_{i=1}^n w_i \cdot r_i \quad (11)$$

此方法通过将信息分布在多个神经元上有效处理噪声信号，增强鲁棒性。它提高了模式的线性可分性，帮助SVM等分类器在语音分类等任务中实现高精度 [83]。

4 实验研究

我们的实验研究调查了单变量和多变量时间序列数据集上的多种模型架构，重点关注传统人工神经网络 (ANNs)、先进脉冲神经网络 (SNNs) 和ARIMA模型，实验工作流程图如图2所示。我们特别评估了SNNs在光伏 (PV) 系统时间序列数据预测中的应用。我们使用了来自国家太阳辐射数据库的两个不同的小时数据集[78]。这些数据集源自巴勒斯坦杰宁市 (纬度 = 32.45, 经度 = 35.3) 和约旦安曼市 (纬度 = 31.97, 经度 = 35.94)，覆盖了2017年至2019年的时间段。这些数据集对于训练和验证我们用于1小时前全球水平辐射 (GHI) 预测的模型至关重要，其中80%的数据用于训练，剩余20%用于测试。我们纳入ARIMA模型作为基准传统统计模型，以提供与我们神经网络方法相比的基线。气象参数的详细信息汇总在表2中。

图2 实验工作流程图。该流程从国家太阳辐射数据库获取数据集开始，随后进行数据预处理（归一化和时间序列窗口化）。开发了三种模型架构（ANN、SNN、ARIMA），并使用特定的编码方案（ Σ - Δ 编码和速率编码）进行训练。模型使用RMSE、MAE和nRMSE评估太阳能辐射预测精度，并使用SNN的能量效率指标评估计算可持续性




表2 数据集的气象主要特征描述

特征名称	Type	描述
Date	Date	小时时间戳
GHI	浮点数	目标标签—平均全球水平辐射 (W/m^2)
空气温度	浮点数	平均气温 (摄氏度)
露点	浮点数	空气完全饱和并形成露水的温度，以摄氏度表示
相对湿度	浮点数	平均相对湿度
风向	浮点数	从真北顺时针的角度表示的风向
风速	浮点数	最大风速 (米/秒)

注意：该表格描述了数据集的主要气象特征

在我们的实验设置中，我们将SNN的性能与LSTM、MLP、CNN和ARIMA模型等传统ANN架构进行基准测试。对于ARIMA模型，我们使用了pmdarima Python库中的auto arima函数来自动选择最佳参数，并指定季节周期为24以考虑每日周期性模式。这种方法通过最小化赤池信息准则（AIC）来平衡模型复杂度和拟合优度。此外，为了提高预测精度，我们将外生变量——气温、露点、相对湿度、风向和风速——纳入ARIMA模型，从而得到ARIMAX模型，这些模型为预测任务提供了有价值的上下文信息。

我们的模型集成了两种神经元动力学模型，Sigma-Delta LIF 和 CUBA-LIF，用于评估它们在单变量和多变量时间序列场景中的有效性。ANN 模型采用传统方法进行训练，而 SNN 模型则采用两种不同的方法进行训练：使用 SLAYER 2.0 进行直接训练，以及一种改进的 Bootstrap 方法用于 ANN 到 SNN 的转换。Bootstrap 方法通过迭代优化训练过程，以 closely mimic 传统 ANNs 中 ReLU 激活函数的 rate-based 行为 [37]。这种结构化方法确保 ANN 和 SNN 在可比条件下运行，从而促进对其预测性能和计算效率的公平比较。

此外，ARIMA 模型在单变量和多变量设置中进行了配置和评估，作为神经网络模型的稳健基准。所有模型均使用一致的指标进行性能评估，包括归一化均方根误差 (nRMSE)、均方根误差 (RMSE) 和平均绝对误差 (MAE)，从而能够全面比较它们的预测能力。

4.1 实验框架

这些数据集涵盖了建模 GHI 所需的气象参数，具体见表 2。对杰宁和安曼的气象数据进行了全面的描述性分析，每个数据集包含 26,280 个观测值。结果分别见表 3（杰宁）和表 4（安曼）。杰宁数据集的气温平均值为 21:23°C，标准差为 7:60°C，表明温度变化适中。露点平均为 12:86°C，相对湿度维持在 63.86% 的平均水平，显示湿度水平相对稳定。杰宁的风向集中在 220°，风速平均为 1.60 m/s。值得注意的是，杰宁的太阳辐射（GHI）平均值为 221.70 W/m²，反映了充足的太阳能资源。相比之下，安曼数据集记录的气温平均值略低，为 18:02°C，但标准差更高，为 8:83°C，表明温度波动更显著——安曼的露点和相对湿度分别平均为 8:01°C 和 59.97%。安曼的风向主要朝向 234°，风速更高，平均为 2.63 m/s。与杰宁相比，安曼的太阳辐射（GHI）平均值更高，为 250.75 W/m²，凸显了更强的太阳能潜力。这些统计数据

表3 贾宁数据集气象参数描述性统计

统计量	空气温度 (°C)	露点 (°C)	相对湿度 (%)	风向 (°)	风速 (m/ s)	太阳辐射 (GHI) (W/ m ²)
计数	26,280	26,280	26,280	26,280	26,280	26,280
Mean	21.23	12.86	63.86	220.06	1.60	221.70
Std	7.60	5.52	22.29	102.56	0.74	312.21
Min	1.50	-6.90	11.05	0.00	0.10	0.00
25%	15.00	8.90	44.55	134.00	1.00	0.00
50%	21.30	12.60	66.95	253.00	1.50	0.00
75%	26.30	17.30	83.85	302.00	2.10	418.00
Max	41.20	24.40	100.00	360.00	5.40	1,052.00

表4 安曼数据集中气象参数的描述性统计

统计	空气温度 (°C)	露点 (°C)	相对湿度 (%)	风向 (°)	风速 (m/ s)	太阳辐射 (GHI) (W/ m ²)
计数	26,280	26,280	26,280	26,280	26,280	26,280
Mean	18.02	8.01	59.97	234.39	2.63	250.75
Std	8.83	5.85	27.54	86.59	1.49	333.92
Min	-3.30	-11.90	7.43	0.00	0.20	0.00
25%	10.90	4.30	35.66	155.00	1.40	0.00
50%	17.90	7.80	59.07	270.00	2.30	0.00
75%	24.00	12.10	85.45	300.00	3.60	513.00
Max	40.90	21.20	100.00	360.00	9.20	1,086.00

为两个地区的气候条件提供了关键见解，为后续的太阳辐射预报和能源优化工作提供了依据。

在此基础上，我们继续探讨两种分析的具体细节：

- 单变量时间序列分析：我们仅关注太阳辐射指标，单变量分析旨在基于历史数据点进行预测。时间 ‘t’ 的数据受 $t - 3$ 、 $t - 2$ 和 $t - 1$ 等先前值的影响。该方法利用最后三个时间步的数据，实现了对后续小时的预测。
- 多变量时间序列分析：我们基于单变量方法构建了多变量分析，并整合了五个与目标相关的气象参数（特征）来预测太阳辐射值。与单变量方法类似，我们同样利用过去三个小时的数据进行预测。

在此，我们概述了单变量和多变量分析所采用的标准化预处理步骤。

- 归一化：我们对所有数据集进行了归一化处理，使用 Python scikit-learn 库中的最小-最大缩放器方法将数据调整到 0-1 范围。
- 数据转换用于SNNs输入：在准备我们的SNNs数据集时，我们启动了特定的数据转换，以使传统的时间序列数据适应于SNNs的监督学习。
- 时间序列窗口化：我们首先将时间序列数据划分为序列，以作为输入我们模型的特性。具体来说，我们配置了序列大小（滞后）为3；使用三个滞后的决定是基于实证证据，并在第5.4节中进一步阐述，这意味着我们使用了当前时间步和前两个时间步作为每个实例的输入特征，旨在预测后续时间步。

这些模型的效能通过三个主要指标进行了严格量化：RMSE、MAE和nRMSE。RMSE提供了预测误差平均幅度的度量，通过公式(12)计算：

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (P_i - O_i)^2}, \quad (12)$$

其中 P_i 表示预测值， O_i 表示观测值。相应地，nRMSE 由公式 (13) 定义：

$$\text{nRMSE} = \frac{\text{RMSE}}{O_{\max} - O_{\min}}, \quad (13)$$

它将 RMSE 相对于观测数据范围 $O_{\max} - O_{\min}$ 进行归一化，从而允许在不同数据规模之间进行性能比较。MAE 评估指标由公式 (14) 定义：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |P_i - O_i|, \quad (14)$$

MAE 衡量一组预测中误差的平均幅度，不考虑其方向。除了这些准确率指标外，通过一套综合的能量消耗指标来评估能量效率，这些指标源自 SNN 的事件驱动运行效率。能量消耗基于网络推理期间突触操作 (Synops) 和神经元更新的数量进行评估，为模型的运行效率和可持续性提供洞察。分析包括计算每个 Synops 的能量 (E_S) 和每个神经元更新的能量 (E_N)，将这些指标整合到我们的整体性能评估框架中。此外，我们采用三种互补的方法来评估能量效率。基于 KerasSpiking 的能量估计，它使用突触和神经元操作提供高级别的能量消耗近似值；一个以 Synops 为焦点的理论框架，它根据与硬件无关的 Synops 计算和 MAC 及脉冲累积操作的能量常数来量化能量使用；以及使用 nvidia-smi 库 [84]，进行的经验 GPU 功率测量，它捕获了在 Tesla GPU T4 上训练和推理时的实时能量消耗。这种多指标评估能够对模型的预测准确性和在太阳能辐照度预测等对能量敏感的环境中适用性进行稳健评估。

4.2 实验设计与超参数调优

我们通过探索一个具有单个隐藏层的简单 SNN 设计进行优化。这个基线模型帮助我们理解了性能评估所需的最小可行配置。我们的架构选择过程是经验性的，从更简单的设置开始，逐步增加复杂性。我们系统地增加更多层，在每个阶段评估性能、学习稳定性和收敛性。我们的实验表明，具有两个隐藏层的配置能获得最佳结果。进一步增加层数并没有显著提升性能。因此，我们在所有神经网络类型 (LSTM、MLP 和 CNN) 中采用了这种两层设置，如表 7 所示。这种结构化方法确保我们选择的架构适合稳定性和性能，为后续的 ANN、SNN 和 ARIMA 模型之间的比较提供了坚实的基础。

为了提供具体细节，调优过程包括对学习率、批处理大小和神经元参数 (例如阈值和衰减率) 的调整。每个参数都通过迭代修改来确认其对网络性能的影响。如表 5 和表 6 所示，这些最佳参数是通过全面的评估得出的。对于 ANN，我们使用 Adam 优化器，而对于 SNN，我们使用 RAdam 优化器 [85]，这反映了每种模型独特的需求，以实现最有效的学习动态。

我们使用 Python PyTorch 计算框架进行 ANNs 的平滑模型构建和训练。传统反向传播技术促进了实际模型训练。表 7 提供了 ANNs、SNNs 和 ARIMA 模型的架构和配置的详细概述，包括每类网络的重要设置信息，如层数、神经元数量、激活函数等。

表5 网络超参数调优总结。该表简洁概述了大规模超参数调优研究的结果

参数	范围/选项检查	ANN 和 SNN 找到的最佳参数
神经元	10–100	32
CNN层过滤器	32–64	32
激活	Relu, sigmoid, selu	Relu
优化器	Adam, RAdam, SGD, RMSprop	ANN中的Adam和SNN中的RAdam
学习率	0.001–0.1	0.001
批大小	16–256	64
周期	20–120	60
隐藏层	1–4	2

此表总结了为ANN和SNN模型找到的最佳超参数

表6 SNN神经元超参数调优

神经元类型	参数	范围/选项已勾选	找到的最佳参数
Sigma-Delta LIF	神经元的阈值	0.01–0.9	0.05
Sigma-Delta LIF	tau_grad	0.01–0.9	0.05
Sigma-Delta LIF	scale_grad	1–3	1
Sigma-Delta LIF	需要_梯度	True, False	True
Sigma-Delta LIF	共享_参数	True, False	True
CUBA-LIF	神经元阈值	0.01–1.5	0.5
CUBA-LIF	current_衰减	0.03–1	1
CUBA-LIF	电压_衰减	0.03–0.25	0.03
CUBA-LIF	tau_梯度	0.01–1	1
CUBA-LIF	scale_grad	1–3	1

表7 网络架构和配置

网络	层	架构	神经元类型	编码	训练
ARIMA	—	ARIMA(1,0,0)(1,1,1)[24]	—	None	自动化的auto arima_
ANN	LSTM	三层: 一层LSTM层, 两层隐藏层	ReLU	None	直接/反向传播
ANN	MLP	两层隐藏(密集)层	ReLU	None	直接/反向传播
ANN	CNN	四层: 2个卷积层, 两层隐藏(密集)层	ReLU	None	直接/反向传播
SNN	MLP	两个隐藏(密集)层	Sigma-Delta LIF Sig		直接/SLAYER
SNN	CNN	四层: 2个卷积层, 两个隐藏(密集)层	Sigma-Delta LIF	Sigma-Delta	Direct/SLAYER
SNN	MLP	两个隐藏(密集)层	CUBA-LIF	速率编码	ANN-to-SNN/Bootstrap
SNN	CNN	四层: 2个卷积层, 两个隐藏(密集)层	CUBA-LIF	速率编码	ANN到SNN/引导

4.3 SNNs 实验研究、编码方案性能分析及模型对比框架

4.3.1 SNNs 实验研究

我们的实验使用 Intel LAVA 框架的 SLAYER 2.0 或 Bootstrap 方法为特定模型需求定制 SNN 架构, 用于 ANN 到 SNN 的转换。我们应用这些训练策略于不同的网络架构——LSTM、MLP 和 CNN, 以评估它们在单变量和多变量时间序列数据集上的性能。所有模型, 无论是直接训练还是转换技术, 都使用 80% 的数据用于训练和 20% 的数据用于测试进行了一致性评估。

SLAYER 2.0 专门应用于可以直接训练脉冲模型的网络中，使我们能够利用其处理非可微分的脉冲事件的能力。相反，当需要从传统的 ANN 架构逐步过渡到 SNN 时，会使用 Bootstrap 方法，确保转换过程中性能损失最小。每种训练方法的部署取决于任务的性质以及所使用的特定网络类型。此外，ARIMA 模型使用类似的数据分割进行训练和评估，以保持比较框架的一致性。

4.3.2 编码方案性能分析

为了系统地评估不同编码方案对我们 SNN 模型的有效性，我们进行了广泛的实验，使用了率编码、首次脉冲时间 (TTFS)、种群编码和 Sigma-Delta 编码。我们在 Jenin 和 Amman 数据集上，针对多个模型 (MLP 和 CNN) 和训练算法 (SLAYER 直接训练使用 Sigma-Delta LIF 神经元和 ANN 到 SNN 的 Bootstrap 转换使用 CUBA-LIF 神经元) 评估了这些方案。性能使用 RMSE、MAE 和 nRMSE 进行测量。详细结果展示在表 8 和表 9 中。

对于使用 SLAYER 直接训练算法和 Sigma-Delta LIF 神经元的模型，Sigma-Delta 编码在 100 个时间步长上始终实现了最低的 nRMSE，并在大多数评估指标 (RMSE 和 MAE) 中优于其他编码方案。这表明当与 SLAYER 直接训练结合使用时，Sigma-Delta 编码在捕获数据集的时间动态方面非常有效。相反，对于使用 ANN-to-SNN 引导转换方法和 CUBA-LIF 神经元训练的模型，16 个时间步长的速率编码表现最佳。它在大多数模型中实现了最低的 nRMSE，并在 RMSE 和 MAE 方面优于其他编码方案。这表明速率编码与引导转换方法和 CUBA-LIF 神经元对我们的数据集更兼容。

基于这些实证结果，我们选择了 Sigma-Delta 编码与 SLAYER 直接训练的 Sigma-Delta LIF 神经元，以及使用引导转换的率编码 CUBA-LIF 神经元进行研究。这些选择得到了其优越性能的支持，如表 8 和表 9 中评估指标所示。

表 8 在 Jenin 和 Amman 数据集上使用不同编码方案（在 Sigma-Delta LIF 神经元和 SLAYER 直接训练算法上）的所有 SNN 模型的评估指标，粗体值表示每个指标的最佳性能

网络	时间序列	编码	RMSE Jenin	MAE Jenin	nRMSE Jenin	RMSE 安曼	MAE 安曼	nRMSE 安曼
MLP	Uni	Sigma-delta	64	33	0.060	31.49	18	0.028
	Uni	速率编码	88	50	0.084	75.00	45	0.069
	Uni	TTFS	67	33	0.064	43.00	24	0.040
	Uni	种群	62	31	0.061	31.00	18	0.029
CNN	Uni	Σ - Δ	60	28	0.056	32.40	14.7	0.024
	Uni	速率编码	78	60	0.082	74.00	45	0.068
	Uni	TTFS	65	37	0.062	43.00	24	0.040
	Uni	种群	60	29	0.056	29.00	16	0.027
MLP	多	Σ - Δ	53	31	0.050	39.00	22	0.025
	多	评分编码	74	50	0.071	63.00	45	0.058
	多	TTFS	57	30	0.055	39.00	23	0.036
	多	人口	55	27	0.052	29.00	15	0.026
CNN	多	Σ - Δ	52	25	0.048	32.00	28	0.022
	多	速率编码	74	50	0.070	63.00	46	0.057
	多	TTFS	57	34	0.055	40.00	24	0.037
	多	人口	54	26	0.052	32.00	19	0.027

表 9 使用不同编码方案在 CUBA-LIF 神经元和 ANN-to-SNN 自举转换训练算法上对 Jenin 和 Amman 数据集的所有 SNN 模型的评估指标, 粗体值表示每个指标的最佳性能

网络	时间序列	编码	RMSE Jenin	MAE Jenin	nRMSE Jenin	RMSE Amman	MAE 安曼	nRMSE 安曼
MLP	Uni	速率编码	63.62	36	0.060	30.8	17	0.026
	Uni	Σ - Δ	74	38	0.071	58	31	0.053
	Uni	TTFS	86	58	0.083	100	75	0.075
	Uni	人口	70	40	0.065	45	28	0.040
CNN	Uni	速率编码	65.32	30	0.057	31.75	17	0.025
	Uni	Sigma-Delta	78	41	0.074	61	33	0.055
	Uni	TTFS	79	52	0.080	88	68	0.072
	Uni	人口	76	48	0.059	44	24	0.038
MLP	多	率编码	51.96	28	0.049	23.12	18	0.024
	多	Sigma-Delta	62	41	0.058	46	36	0.039
	多	TTFS	99	70	0.088	84	63	0.075
	多	人口	69	43	0.059	66	19	0.061
CNN	多	比率编码	50.90	29	0.048	22.60	15	0.022
	多	Sigma-Delta	58	40	0.057	44	31	0.036
	多	TTFS	89	68	0.080	76	59	0.071
	多	种群	65	41	0.057	52	17	0.060

4.3.3 模型比较框架

该实验设置允许对ANNs、SNNs和ARIMA模型进行直接比较, 这对于评估它们在预测太阳辐射方面的效率至关重要。为确保公平比较, 所有模型在层数和神经元密度方面采用了相似的架构, 并在实际条件下尽可能使用相同的超参数。这种一致性对于确保观察到的性能差异真正归因于模型类型 (ANN vs. SNN vs. ARIMA) 而非外部配置变量至关重要。所有编码和模型训练均在Google Colab上完成, 利用了NVIDIA Tesla GPU T4的计算能力。由于训练ANNs、SNNs和ARIMA模型需要大量计算资源, 这种设置确保了我们的实验结果可重复且高效获取。此外, 用于运行实验的代码也已公开。²

5 结果与讨论

5.1 模型性能分析

5.1.1 详细可训练参数分析:

我们的分析深入探讨了不同模型中可训练参数的数量, 如表10所示。尽管SNNs使用相似的架构框架, 但其可训练参数数量通常低于ANNs。这种差异源于神经元建模的固有不同。SNNs采用脉冲神经元, 每个神经元所需的参数比ANNs少, 因为突触输入和输出处理方式不同, 通常导致权重更少, 但存在更多状态变量, 这些变量不进行训练而是通过模型本身的动态确定。此外, SNNs可以更有效地利用时间动态, 减少实现可比复杂性和功能所需的可训练参数数量。这种可训练参数的有效减少可以降低计算开销, 但也可能影响训练动态, 如不同数据集上性能指标的变化所示。

² <https://github.com/bahgatayasi/Solar-Radiation-Forecasting-SNNs-ANNs-Source-Files.git>.

表10 每个模型配置的可训练参数数量

网络	Type	时间序列	编码	可训练参数
ANN	LSTM	多	None	8,801
ANN	LSTM	Uni	None	6,881
ANN	MLP	多	None	2,753
ANN	MLP	Uni	None	2,273
ANN	CNN	多	None	21,729
ANN	CNN	Uni	None	6,369
SNN	MLP	多	Σ - Δ	1,640
SNN	MLP	Uni	Σ - Δ	1,160
SNN	CNN	多	Σ - Δ	3,692
SNN	CNN	Uni	Σ - Δ	3,212
SNN	MLP	多	Rate	1,634
SNN	MLP	Uni	Rate	1,152
SNN	CNN	多	Rate	3,682
SNN	CNN	Uni	Rate	3,202

可训练参数的有效减少可以降低计算开销，但也可能影响训练动态，如不同数据集上性能指标的变化所示。

5.1.2 模型性能分析与影响

表11中的结果展示了RMSE和nRMSE的变化情况，这些变化可归因于Jenin和Amman数据集特征的不同。对于Jenin数据集，使用CNN架构的ANNs的RMSE值在48之间，而使用带率编码的CNN的SNNs的RMSE值为65.32。相应地，nRMSE值在0.047到0.060之间，反映了模型精度的细微但影响显著的不同。对于Amman数据集，RMSE值在17.37到39.09之间波动，而nRMSE值在0.016到0.028之间，表明在不同设置下模型准确性的变化。

如表11所示，ARIMA模型通常比ANN和SNN模型表现出更高的RMSE和MAE值，表明预测精度较低。这些结果表明，神经网络在建模太阳能辐射数据中固有的复杂非线性关系方面比传统统计模型（如ARIMA）更有效。

图3和图4直观地比较了不同网络架构和训练方法学下的nRMSE，突出了两个数据集的细微性能指标。这项分析的具体观察结果包括：

- SNNs擅长建模预测问题，并理解网络运行中的复杂性和细节。受生物神经元启发的脉冲机制，使SNN能有效处理数据中的复杂非线性变化。这种强大的建模能力使SNN适合需要高计算完整性和非线性动力学（如太阳辐射预测）的任务。
- 对于单变量和多变量时间序列，在Jenin数据集上，具有CNN、LSTM和MLP架构的ANNs表现相似。值得注意的是，在CNN多变量系列中使用Sigma-Delta LIF和Sigma-Delta编码，并采用SLAYER直接代理训练的SNN网络，在Jenin数据集上的表现与ANNs（MLP、CNN、LSTM）相当。此外，在CNN多变量系列中使用CUBA-LIF神经元和速率编码，并采用bootstrap ANN到SNN间接学习方法的SNN网络，在Jenin数据集上的表现也与这些ANNs相似。

表11 实验结果比较了用于太阳辐射预测的三组模型：ANN、使用SLAYER方法训练的SNN和Bootstrap方法训练的SNN。每组中表现最佳的模型以粗体突出显示，基于每个数据集（Jenin和Amman）的最小归一化RMSE（nRMSE）误差。

网络层数	时间	系列	神经元	编码	训练	RMSE 杰宁	MAE 杰宁	nRMSE 杰宁	RMSE 安曼	MAE 安曼	nRMSE 安曼
ARIMA	—	Uni	—		自动化 自动ARIMA_	58.00	32.0	0.055	35.00	22.0	0.032
ARIMA	—	多	—	None	自动化 自动 ARLMA_	65.00	48.0	0.062	26.00	26.0	0.034
ANN	LSTM	多	ReLU	—	反向传播	50.00	27.8	0.047	18.00	12.7	0.017
ANN	LSTM	Uni	ReLU	—	反向传播	57.80	31.0	0.053	23.00	13.7	0.020
ANN	MLP	多	ReLU	—	反向传播	49.80	27.0	0.047	17.37	16.0	0.018
ANN	MLP	Uni	ReLU	—	反向传播	57.30	31.6	0.053	23.02	14.0	0.022
ANN	CNN	多路	ReLU	—	反向传播	48.34	24.0	0.047	18.46	12.7	0.016
ANN	CNN	Uni	ReLU	—	反向传播	59.80	30.0	0.053	26.06	23.0	0.021
SNN	MLP	多路	Σ - Δ LIF	Sigma- Delta	SLAYER	53.00	31.0	0.050	25.09	22.0	0.025
SNN	MLP	Uni	Sigma- Delta LIF	Sigma- Delta	SLAYER	64.00	33.0	0.060	31.49	18.0	0.028
SNN	CNN	多	Sigma- Delta LIF	Sigma- Delta	SLAYER	52.00	25.0	0.048	22.58	28.0	0.022
SNN	CNN	Uni	Σ - Δ LIF	Σ - Δ	SLAYER	60.00	28.0	0.056	24.10	14.7	0.024
SNN	MLP	Multi	CUBA- LIF	Rate 编程	Bootstrap	51.96	28.0	0.049	23.12	18.0	0.024
SNN	MLP	Uni	CUBA- LIF	速率编程	Bootstrap	63.62	36.0	0.060	30.83	17.7	0.026
SNN	CNN	多	CUBA- LIF	费率编码	Bootstrap	50.90	29.0	0.048	22.60	15.0	0.022
SNN	CNN	Uni	CUBA- LIF	费率编码	Bootstrap	65.32	30.0	0.057	31.75	17.0	0.025

- 对于单变量序列，结合CNN的SNN在MLP上展现出竞争优势，尤其是在阿曼数据集。
- 使用SLAYER 2.0直接训练的Sigma-Delta LIF神经元SNN，表现出强大的训练和收敛能力，在两个数据集的多变量序列中尤为明显。
- 使用速率编码和CUBA-LIF神经元从ANN转换为SNN被证明有效，这在两个数据集的结果中得到了突出显示。

关于RMSE，必须将其重要性置于太阳能辐射预报的特定框架内进行理解。该指标量化了预测误差的平均幅度，表明模型在估计GHI方面的准确性。理解RMSE值至关重要，因为它们直接反映了模型预测太阳能可用性的精确度，而太阳能可用性是优化和评估光伏系统效率的关键因素。

- 阿曼数据集的均方根误差（RMSE）为17.37，意味着太阳辐射（GHI）预测的平均误差约为17.37个单位。考虑到该数据集在白天不同时段的数值变化范围很大，这一




图3 网络架构与训练方法论的nRMSE（杰宁数据集）




图4 网络架构与训练方法论的nRMSE（安曼数据集）

均方根误差（RMSE）的数值表明，考虑到全天太阳辐射的变化性，其精度相对较高。

对于杰宁数据集，RMSE为48代表模型预测太阳辐射的平均误差。虽然高于安曼数据集，但考虑到杰宁可能存在显著差异的环境和大气条件，这个值仍然反映了合理的预测精度。

虽然我们的研究结果表明，具有内在事件驱动处理能力的SNNs具有显著潜力，但它们在所有场景中并不都统一匹配ANNs的性能。SNNs的性能显著取决于编码方案和神经元模型的选择。这表明，SNNs虽然有可能超越ANNs，但需要精心调整参数和谨慎的架构决策才能实现最佳性能。尽管SNNs在准确度指标上未能超越ANNs，但它们在参数和能耗方面效率更高，正如下一节中的能耗分析所证明的那样。这些模型的比较有效性表明，虽然先进机制可以提升性能，但正如相关工作部分所述，我们研究中使用的更简单的模型也能产生稳健的预测。这对于智能电网中的能源管理应用尤为重要，因为平衡计算需求与运营效率至关重要。这表明，即使采用更直接的技术实现，可再生能源预测领域也能取得重大进展。

接下来，我们将探讨性能、功耗和网络稀疏性之间的相互作用，并进一步讨论能效问题，这对于这些网络的实际部署至关重要。

5.2 稀疏性指标分析

表12中的比较突出了使用SNNs相对于ANNs在计算稀疏性方面的显著优势。我们通过分析测试数据集上的网络模型在推理过程中，经验性地计算了SNNs的稀疏性。具体来说，我们测量了SNNs中的神经元激活次数（事件）和Synops数量。我们将这些指标与等构ANN进行了比较——即具有相同架构但无脉冲行为的ANN。我们运行训练好的SNN模型在测试数据上进行量化分析，并在推理过程中统计了实际事件（脉冲）和Synops数量。这些计数在测试样本上进行了平均，以获得平均活动水平。通过这些经验计数与等效ANN中可能的总激活次数和Synops进行比较，我们推导出了事件减少因子和Synops减少因子，量化了神经元激活和突触操作的减少量。在我们的实验中，使用Sigma-Delta LIF神经元和Sigma-Delta编码的网络比使用CUBA-LIF神经元和速率编码的网络表现出显著更高的稀疏性水平。从表12中列出的事件减少因子和Synops减少因子可以看出，Sigma-Delta配置实现了最高的减少量。这些结果表明，SNNs激活的神经元远少于其ANN对应物，并且执行了显著更少的突触操作。这种增加的稀疏性表明SNNs可以最小化计算开销，从而降低能耗——这是我们在下一节中进一步探讨的益处。

5.3 SNNs与ANNs中能效的全面分析

在本节中，我们采用三种互补的方法考察SNNs与ANNs的能效。通过整合基于KerasSpiking的估计（方法#1）、以Synops为中心的理论框架（方法#2）以及精确的GPU功率测量（方法#3），我们提供了对SNN能效在不同硬件和建模范式下的稳健、多角度分析。

5.3.1 方法#1（KerasSpiking能效估计）。

在我们评估能效的第一种方法中，我们遵循了 [86] 的方法，该方法依赖于 KerasSpiking 库 [87] 来估计 SNN 和 ANN 的每项推理能耗。KerasSpiking 使用突触和神经元操作的高级抽象，并集成了经验性或基于文献的常数，以生成近似能耗估计。这些硬件常数源自 KerasSpiking 自身的文档 [87]，并基于已发布的、尽管是泛化的设备规格。KerasSpiking 框架与 TensorFlow/Keras 无缝集成，提供了一个简化的工作流程，简化了模型训练、推理和能耗估计。通过结合“放电事件”

表12 比较SNNs和ANNs在Jenin和Amman数据集上的事件和Synopsis稀疏性，加粗值突出显示最高减少量，从而体现最显著的效率提升

数据集	网络	层数	时间序 列	神经元	编码	训练	SNN事件减少 因子	SNN概要减少因子
杰宁	SNN	MLP	多	Σ - Δ LIF	Σ - Δ	SLAYER	6.68x	4.62x
	SNN	MLP	Uni	Sigma-Delta LIF	Sigma- Delta	SLAYER	34.88x	29.93x
	SNN	CNN	多	Σ - Δ LIF	Σ - Δ	SLAYER	10.34x	8.95x
	SNN	CNN	Uni	Sigma-Delta LIF	Sigma- Delta	SLAYER	28.87x	28.96x
	SNN	MLP	多频	CUBA-LIF	Rate 编码	Bootstrap	3.41x	4.0x
	SNN	MLP	Uni	CUBA-LIF	Rate 编码	Bootstrap	5.35x	5.61x
	SNN	CNN	多	CUBA-LIF	Rate 编码	Bootstrap	6.2x	7x
	SNN	CNN	Uni	CUBA-LIF	Rate 编程	Bootstrap	8.15x	9.6x
安曼	SNN	MLP	多	Σ - Δ LIF	Sigma- Delta	SLAYER	6.70x	4.75x
	SNN	MLP	Uni	Sigma-Delta LIF	Sigma- Delta	SLAYER	36.19x	33.64x
	SNN	CNN	Multi	Sigma-Delta LIF	Sigma- Delta	SLAYER	10.27x	9.09x
	SNN	CNN	Uni	Σ - Δ LIF	Σ - Δ	SLAYER	32.61x	36.38x
	SNN	MLP	多	CUBA-LIF	Rate 编码	Bootstrap	4.71x	5.59x
	SNN	MLP	Uni	CUBA-LIF	Rate 编码	Bootstrap	6.15x	6.47x
	SNN	CNN	多	CUBA-LIF	费率编码	引导	7.20x	8.5x
	SNN	CNN	Uni	CUBA-LIF	费率编码	Bootstrap	12.6x	14.1x

SNNs中的概念，该框架通过事件驱动操作有效地考虑了潜在的节能。此外，KerasSpiking与现有研究高度一致，这一点在其被用于各种研究[86, 88, 89]中得到证明。这些研究利用KerasSpiking评估了SNNs的能效，并将其性能与ANNs进行了基准测试，特别是在小规模研究项目和概念验证分析中。尽管KerasSpiking为能效评估提供了一个方便的高级工具，但它缺乏针对硬件特定精度的严格同行评审验证。其文档明确警告称，这些预测应被视为“非常粗略的估计”，实际消耗受设备架构、数据传输开销和其他因素的影响。因此，我们将这些数字视为一个概念性基准，并辅以更详细的理论（第5.3.2节）和实证（第5.3.3节）方法。

能耗公式。基于SNN稀疏性（即激活突触事件少于密集ANN计算）的概念，我们采用KerasSpiking的概念框架来估算每次推理的近似能耗。遵循先前研究 [86–89]，，我们定义了两个核心能耗组件：

- Synopsis Energy (ES):

$$E_S = E_o \times S \quad (15)$$

其中 E_o 是每项突触操作的能耗 (Synops), S 是推理期间的总突触事件数。在 SNN 中, 每个突触事件对应一个脉冲接收; 在 ANN 中, 它类似于每次乘累加 (MAC) 操作。

- 神经元更新能量 (E_N):

$$E_N = E_u \times U \quad (16)$$

其中 E_u 表示每个神经元更新的能量成本, U 是膜更新的总数 (SNN) 或神经元激活的总数 (ANN)。

- 总能量消耗 (E_{total}):

$$E_{total} = E_S + E_N. \quad (17)$$

表14展示了 E_o 和 E_u (单位: 纳焦耳) 在两种硬件范式——传统GPU (例如NVIDIA GTX Titan Black) 和Loihi神经形态平台——在 [86, 87] 中的典型值。随着更多特定硬件数据的可用, 这些常数可能进行调整。

5.3.2 结果与讨论

尽管 KerasSpiking 模型具有近似性, 但我们的估计在各种基准测试中始终表明, 与 ANNs 相比, SNNs 的能耗更低。表 13 显示, 当在神经形态硬件 (例如 Loihi) 上概念性运行时, SNN 配置可以提供高达 $\sim 9\times$ 的推理每能耗降低, 在 GPU 上的改进虽然较为温和, 但仍然显著。表 13 的更仔细检查揭示, 在 Jenin 数据集上, ANN CNN Multimodel 在 NVIDIA GPU 上消耗约 1,148 nJ, 在 Loihi 上消耗 111 nJ, 而其 SNN 对应模型 (使用 Sigma-Delta LIF 神经元和 SLAYER 训练) 在 GPU 上仅消耗 127.61 nJ, 在 Loihi 上仅消耗 12.30 nJ——这代表着 $9\times$ 的改进。在 Amman 数据集上也能观察到类似的节省, 这突显了为事件驱动处理设计的神经形态平台 (如 Loihi) 如何放大 SNN 的能耗优势。值得注意的是, 这些 $9\times$ 和 $7-8\times$ 的增益是在比较 SNN CNN Multimodel (使用 SLAYER 或 Bootstrap 训练) ——根据表格表现的最佳配置——与其对应的 ANN CNN Multimodel 时产生的。SNNs 可以利用事件驱动计算, 相对于密集的 ANN 工作负载减少主动突触操作的次数。传统的基于冯·诺依曼架构的 GPU 无法充分利用基于脉冲的稀疏性。因此, SNN 的能耗优势在像 Loihi 这样的专用神经形态硬件上更为明显。 $\sim 7\times$ 到 $\sim 9\times$ 的改进对于边缘计算或基于光伏的系统尤其相关, 这些系统的可用电源有限。虽然 KerasSpiking 的这些结果加强了 SNN 能效的案例, 但它们得到了更精确的理论和实证方法的补充: (i) 方法 #2: 基于 Synops 的理论计算 (见第 5.3.2 节), 遵循 [92], 来根据硬件级的乘累加 (MAC) 常数近似能耗, 以及 (ii) 方法 #3: 基于 [93], 的实证 GPU 测量 (见第 5.3.3 节), 通过 nvidia-smi 库在 Tesla GPU T4 上捕获实际功耗 [84]。总之, 方法 #1 提供了一种使用已发布常数和近似建模的便捷、高级的 SNN 能耗评估。后续章节将介绍更严格的方法, 用于特定硬件的验证, 以确保全面透明的能效评估。

表 13 SNNs 和 ANNs 在单样本推理中硬件平台的估计能耗（纳焦耳），粗体条目表示最低能量估计，说明 SNNs 相较于 ANNs 的效率提升

数据集	网络	层数	时间序列	神经元	编码	训练	GPU上的Etotal (nJ)	Loihi上的Etotal (nJ)
杰宁	ANN	LSTM	多	ReLU	-	反向传播	2,631	243
	ANN	LSTM	Uni	ReLU	-	反向传播	2,055	191
	ANN	MLP	多	ReLU	-	反向传播	514	50
	ANN	MLP	Uni	ReLU	-	反向传播	366	36
	ANN	CNN	多	ReLU	-	反向传播	1,148	111
	ANN	CNN	Uni	ReLU	-	反向传播	999	97
	SNN	MLP	多路	Σ - Δ LIF	Σ - Δ	SLAYER	109.76	10.59
	SNN	MLP	Uni	Σ - Δ LIF	Sigma-Delta	SLAYER	12.52	1.24
	SNN	CNN	Multi	Sigma-Delta LIF	Sigma-Delta	SLAYER	127.61	12.30
	SNN	CNN	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	33.44	3.27
	SNN	MLP	多频	CUBA-LIF	速率编码	Bootstrap	129.74	13.04
	SNN	MLP	Uni	CUBA-LIF	速率编码	Bootstrap	65.46	6.60
	SNN	CNN	多	CUBA-LIF	评分编码	Bootstrap	163.23	16.03
	SNN	CNN	Uni	CUBA-LIF	评分编码	Bootstrap	104.29	10.30
阿曼	ANN	LSTM	多	ReLU	-	反向传播	2,631	243
	ANN	LSTM	Uni	ReLU	-	反向传播	2,055	191
	ANN	MLP	多	ReLU	-	反向传播	514	50
	ANN	MLP	Uni	ReLU	-	反向传播	366	36
	ANN	CNN	多路	ReLU	-	反向传播	1,148	111
	ANN	CNN	Uni	ReLU	-	反向传播	999	97
	SNN	MLP	多	Σ - Δ LIF	Σ - Δ	SLAYER	106.85	10.32
	SNN	MLP	Uni	Σ - Δ LIF	Σ - Δ	SLAYER	10.84	1.08
	SNN	CNN	多	Σ - Δ LIF	Σ - Δ	SLAYER	125.69	12.13
	SNN	CNN	Uni	Σ - Δ LIF	Sigma-Delta	SLAYER	27.60	2.71
	SNN	MLP	Multi	CUBA-LIF	Rate coding	Bootstrap	92.91	9.35
	SNN	MLP	Uni	CUBA-LIF	速率编码	引导	56.73	5.72
	SNN	CNN	多	CUBA-LIF	速率编码	Bootstrap	135.69	13.36
	SNN	CNN	Uni	CUBA-LIF	速率编码	Bootstrap	70.93	6.97

5.3.3 方法论 #2：基于概要的理论能量估算

我们基于 [92] 中提出的框架实现了一种理论方法。这种方法将突触操作（Synops）量化为 SNN 能耗的主要驱动因素，这与 ANNs 通常使用的乘累加（MAC）操作形成对比。我们通过计算每一层的 Synops 并乘以 MAC 和脉冲累加操作已知的能耗常数，从而推导出一种硬件无关但原则性的能耗消耗近似值。

5.3.4 突触运算计算

根据公式(18)，每个SNN层l都需要遵循 [92]：

$$\text{Synops}(l) = f_r \times T \times \text{FLOPs}(l)$$

(18)

其中 f_r 表示放电率（每个神经元每个时间步的脉冲数）， T 是层活动的时间步总数， $FLOPs(l)$ 表示该层的浮点运算特性。我们的实验通过在每个层的推理过程中计数脉冲来测量放电率。

5.3.5 理论能量计算

计算完每一层的 Synops 后，我们应用了来自 [92] 的能量模型，该模型考虑了：- E_{MAC} 用于第一层的 MAC 操作，以及 - E_{AC} 用于后续的尖峰累积（AC）操作。

形式上，对于一个包含 N 个卷积（Conv）层和 M 个全连接（FC）层的 SNN，其总能量消耗如式（19）所示：

$$E_{SNN} = E_{MAC} \times FLOP_{SNNConv}^1 + E_{AC} \times \sum_{n=2}^N Synops_n^{SNNConv} + \sum_{m=1}^M Synops_m^{SNNFC}, \quad (19)$$

其中 $FLOP_{SNNConv}^1$ 表示第一层卷积层的 FLOPs， $Synops_n^{SNNConv}$ 、 $Synops_m^{SNNFC}$ 表示后续层的 Synops。

对于仅由 M 个 FC 层组成的 SNN（不含卷积层），其总能量如式（20）所示：

$$E_{SNN-FC} = E_{MAC} \times FLOP_{SNNFC}^1 + E_{AC} \times \sum_{m=2}^M Synops_m^{SNNFC}, \quad (20)$$

其中 $FLOP_{SNNFC}^1$ 表示第一个全连接层的基于 MAC 的操作，其余层则依赖尖峰（spike）的 AC 操作。

与此同时，对于标准人工神经网络（ANN），其能耗是直接的，因为每个神经元通常会根据公式(21)执行 MAC 运算：

$$E_{ANN} = E_{MAC} \times FLOP_{ANN}, \quad (21)$$

这反映了 MAC 在所有层中的统一使用。

5.3.6 结果与讨论

使用此方法，我们估计了在相同测试数据集划分条件下（参见表 [15] 中的说明性子集），一系列人工神经网络（ANN）和脉冲神经网络（SNN）模型的每样本能耗。具体来说：

- 脉冲神经网络（SNN）模型：在神经形态风格的 MAC+AC 假设下，实现了更低的推理能耗，主要当放电率保持较低时。
- ANN 模型：始终需要更高的 MAC 相关能耗，反映了密集的浮点运算。
- 数据集差异：杰宁和安曼呈现出相似的趋势，但由于数据集特有的因素（例如输入内容的内在变化），绝对能量水平存在差异。

这些理论结果与通过 KerasSpiking（方法 #1）观察到的粗略估计相符，表明 SNN 具有显著的理论节能潜力——尤其是在基于脉冲稀疏性的硬件上实现时。然而，实际性能取决于特定的硬件约束。确实，后续测试（方法 #3）使用非神经形态 GPU 指出，SNN 的优势可能在传统架构上减弱。

5.3.7 限制与未来工作

我们的计算假设了 45 纳米工艺节点和典型的能量常数 ($E_{\text{MAC}} = 4.6\text{pJ}$ 和 $E_{\text{AC}} = 0.9\text{pJ}$)，如 [92] 中所述并由相关文献 [94] 证实。如果在不同技术节点或硬件后端上实现，这些假设可能高估或低估能耗。未来工作可结合神经形态芯片（如 Intel 的 Loihi）的设备级测量，或集成设计时工具（如能量精确模拟器）来进一步优化这些估计。

5.3.8 方法论 #3：使用特斯拉GPU T4硬件进行实证实验

我们使用nvidia-smi库 [84]在NVIDIA Tesla GPU T4上进行了实证实验。这种方法论直接监控我们ANNs和SNNs在训练和推理阶段的实时功耗，从而补充了第5.3.1节和5.3.2节中提出的理论估计。

5.3.9 实验设置和实证结果

实验在一个配备Tesla GPU T4的专用服务器上执行。我们使用nvidia-smi工具（如官方NVIDIA指南 [84]中所述）以每秒一次的间隔进行功耗监控。这种方法与先前的GPU能耗测量文献一致，例如研究 [93] 和其他基于GPU的深度学习能耗研究 [95]。

我们使用nvidia-smi在后台记录每秒的瞬时功耗值（单位：瓦特），从而随时间累积原始功耗读数 $P(t)$ ，以获得总能耗（单位：焦耳（J））。具体来说，每个功耗测量值 $P(t)$ （单位：瓦特）乘以1秒得到 $P(t) \times 1\text{s}$ 焦耳，并将整个记录间隔内的值相加得到总GPU能耗。虽然我们的SNNs利用cuSPARS库[84]管理稀疏矩阵运算，但GPU将这些工作负载作为密集层有效处理，这会影响测量结果。表16总结了Jenin和Amman数据集上训练（Train (J)）和推理（Infer (J)）的实际能耗（单位：焦耳）。我们对ANN和SNN模型重复了此流程。

5.3.10 讨论 и 限制

表16的结果表明，尽管方法#1（理论分析）和方法#2预测SNN的功耗会较低，但我们在Tesla GPU T4上的实证测量显示，SNN的整体能耗更高，这与先前发现的标准GPU未能充分利用脉冲稀疏性 [93, 96–98]的结论一致。与方法#1和方法#2的近似或理论估计相比，这种不匹配突显了实际性能如何取决于底层硬件架构。真正的SNN能效提升可能出现在专用神经形态芯片（例如Intel Loihi）上，这些芯片原生支持事件驱动处理。相比之下，传统GPU会带来开销（例如类似密集的内存传输），从而掩盖了潜在的收益。尽管我们的功耗记录方法能够准确测量GPU在训练和推理过程中的使用情况，但仍存在一些注意事项：(i) nvidia-smi日志忽略了CPU、DRAM和其他系统开销，主要关注GPU功耗；(ii) 每秒采样一次功率可能会错过细粒度的波动；(iii) Tesla GPU T4不是神经形态加速器，因此许多基于脉冲的优势仍未被利用 [93]。总体而言，这些以GPU为中心的实验（方法#3）证实，当在非神经形态硬件上实现时，SNN未能实现脉冲导向文献中观察到的理论能效节省。然而，测量实际行为提供了关于硬件特定约束的关键见解，并证实了先前关于网络优化的研究 [93, 95]。

5.3.11 平衡准确性与功耗

我们的研究考察了模型精度（通过RMSE、nRMSE和MAE等指标衡量）与能效的交集，参考了表11的性能结果以及表13和表15的能量数据。虽然某些SNN配置可以在预测精度上与表现最佳的ANN相媲美，但其他配置可能会产生略微更高的误差，却提供显著的节能效果——这对于优先考虑能效的应用来说是一个有吸引力的权衡。此外，基于KerasSpiking的估计（方法#1）和Synopsis理论模型（方法#2）都表明，SNN擅长减少能耗，特别是在神经形态平台上或脉冲活动稀疏的情况下。然而，在Tesla GPU T4上的实际测量（方法#3）表明，在这些理论收益可能在传统硬件上减弱，因为密集数值运算和内存传输等开销会抵消事件驱动计算的优势。因此，虽然神经形态架构有望释放SNN的全部节能潜力，但标准GPU在基于脉冲的工作负载上仍可能记录更高的功耗。通过强调这些权衡，我们的研究突显了如何定制SNN——平衡精度要求与能效约束——在不同领域，包括可持续技术（如光伏系统）中的应用。

5.4 太阳能辐照度预测的最佳滞后选择

准确预测太阳能辐照度并选择合适的滞后大小对于确保模型准确且功耗低至至关重要。我们的实证研究专注于在预测准确性（以nRMSE表示）和神经形态Loihi硬件平台上模型能耗之间找到平衡。

该研究实验了从1到12的滞后值，以预测太阳能辐照度（1小时）。我们的系统分析涉及计算总事件和Synopsis以估计功耗，并依赖于表14中详细说明了神经形态硬件效率常数。结果表明，在所有滞后设置中，nRMSE和功耗之间存在明显的权衡。

本研究使用了来自杰宁的数据集，该数据集代表每小时太阳辐射，日均日照时间为12小时。经过仔细审查（如表17所示），滞后值为3被确定为最合适的选择。它在预测准确性和功耗之间展现了引人注目的权衡。这一决策的依据不仅基于实证数据；它还得到了我们数据集内在特性和单步预测目标的支撑。

通过选择3小时滞后，我们确保模型能够捕获足够的历史信息以准确预测，同时避免包含可能导致过度复杂化的冗余数据。这种方法优化了性能和能效，特别是在神经形态硬件平台上运行的太阳能辐照度预测模型方面。它确保了高精度，同时保持了低功耗，使其适用于可持续能源系统，并使网络能够在学习稳定性和计算需求的最理想范围内运行。

表14 硬件平台使用的能量常数 E_o 和 E_u (单位: 纳焦耳, nJ), 基于 [86, 87]

硬件平台	E_o (nJ)	E_u (nJ)
GPU (NVIDIA GTX Titan Black) [90]	0.3	0.3
Loihi [91]	0.02711	0.081

表15 神经形态网络（SNNs）与人工神经网络（ANNs）的单次推理步骤理论能耗（单位：纳焦耳）

数据集	网络	层数	时间序列	神经元	编码	训练	估计能耗/nJ
杰宁	ANN	LSTM	多	ReLU	None	反向传播	109.22
	ANN	LSTM	Uni	ReLU	None	反向传播	79.19
	ANN	MLP	多路	ReLU	None	反向传播	24.44
	ANN	MLP	Uni	ReLU	None	反向传播	5.30
	ANN	CNN	多路	ReLU	None	反向传播	67.12
	ANN	CNN	Uni	ReLU	None	反向传播	47.69
	SNN	MLP	多路	Σ - Δ LIF	Σ - Δ	SLAYER	0.56
	SNN	MLP	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	0.37
	SNN	CNN	Multi	Sigma-Delta LIF	Sigma-Delta	SLAYER	1.30
	SNN	CNN	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	1.37
	SNN	MLP	Multi	CUBA-LIF	评分编码	Bootstrap	6.03
	SNN	MLP	Uni	CUBA-LIF	评分编码	Bootstrap	1.35
	SNN	CNN	多	CUBA-LIF	速率编码	引导	4.87
	SNN	CNN	Uni	CUBA-LIF	速率编码	引导	3.20
安曼	ANN	LSTM	多	ReLU	None	反向传播	109.22
	ANN	LSTM	Uni	ReLU	None	反向传播	79.19
	ANN	MLP	多	ReLU	None	反向传播	24.44
	ANN	MLP	Uni	ReLU	None	反向传播	5.30
	ANN	CNN	多路	ReLU	None	反向传播	67.12
	ANN	CNN	Uni	ReLU	None	反向传播	47.69
	SNN	MLP	多路	Σ - Δ LIF	Sigma-Delta	SLAYER	0.55
	SNN	MLP	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	0.38
	SNN	CNN	Multi	Sigma-Delta LIF	Sigma-Delta	SLAYER	1.34
	SNN	CNN	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	1.41
	SNN	MLP	多模	CUBA-LIF	速率编码	引导	6.73
	SNN	MLP	Uni	CUBA-LIF	速率编码	Bootstrap	1.74
	SNN	CNN	多	CUBA-LIF	速率编码	Bootstrap	7.358
	SNN	CNN	Uni	CUBA-LIF	评分编程	Bootstrap	3.24

6 结论与未来方向

我们对用于太阳能辐射预测的ANNs和SNNs的全面评估已经证明了SNNs的潜力，特别是在能源效率方面。虽然我们的比较分析，如第5节中讨论的，使用了多种架构和编码策略，表明SNNs在精度方面表现具有竞争力，但它们在所有指标上并未始终超越LSTM、CNNs和MLPs等传统模型的性能。然而，SNNs在功耗方面表现出显著优势。应用SLAYER算法和Bootstrap转换方法等先进方法使SNNs能够取得显著成果。如表11所示，SNNs在RMSE、MAE和nRMSE等指标上的性能与传统模型相当，同时提供了更优越的能源效率。这突显了SNNs作为太阳能辐射预测的可行且高效的替代方案。在本研究的背景下，全球推动将光伏系统整合到电网中的趋势下，这些发现具有重要意义。这尤其与巴勒斯坦和约旦等阿拉伯国家相关，在这些国家，太阳能是可持续发展的重要组成部分，正如联合国可持续发展目标 [2] 所概述的那样。SNNs的计算效率和低功耗使其特别适用于光伏是主要能源的环境。虽然SNNs提供了具有竞争力的精度，但它们的主要优势在于能够在有限的能源资源下高效运行。这种能力将极大地促进高辐照度地区太阳能基础设施的扩展，

表16 ANNs和SNNs在Jenin和Amman数据集上的训练和推理能耗对比（焦耳，基于Tesla GPU T4的实际经验测量）

数据集	网络	层数	时间序列	神经元	编码	训练	训练 (J)	推理 (J)
杰宁	ANN	LSTM	多模	ReLU	None	反向传播	2572.46	64.68
	ANN	LSTM	Uni	ReLU	None	反向传播	2468.94	65.87
	ANN	MLP	多路	ReLU	None	反向传播	1785.50	64.38
	ANN	MLP	Uni	ReLU	None	反向传播	1458.13	55.55
	ANN	CNN	多路	ReLU	None	反向传播	2089.94	64.48
	ANN	CNN	Uni	ReLU	None	反向传播	2146.45	96.92
	SNN	MLP	多路	Σ - Δ LIF	Σ - Δ	SLAYER	6112.74	84.08
	SNN	MLP	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	4702.47	84.14
	SNN	CNN	Multi	Sigma-Delta LIF	Sigma-Delta	SLAYER	9705.72	82.10
	SNN	CNN	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	6690.08	81.89
	SNN	MLP	Multi	CUBA-LIF	评分编码	Bootstrap	3949.64	24.53
	SNN	MLP	Uni	CUBA-LIF	评分编码	Bootstrap	4049.67	23.56
	SNN	CNN	多语言	CUBA-LIF	费率编码	Bootstrap	6527.20	25.90
	SNN	CNN	Uni	CUBA-LIF	费率编码	Bootstrap	6379.53	25.56
安曼	ANN	LSTM	多	ReLU	None	反向传播	2601.61	65.47
	ANN	LSTM	Uni	ReLU	None	反向传播	2502.28	64.68
	ANN	MLP	多	ReLU	None	反向传播	1712.34	64.38
	ANN	MLP	Uni	ReLU	None	反向传播	1652.19	64.78
	ANN	CNN	多路	ReLU	None	反向传播	2122.66	64.58
	ANN	CNN	Uni	ReLU	None	反向传播	2109.70	64.28
	SNN	MLP	多路	Σ - Δ LIF	Sigma-Delta	SLAYER	6179.97	87.20
	SNN	MLP	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	4849.50	87.40
	SNN	CNN	Multi	Sigma-Delta LIF	Sigma-Delta	SLAYER	9683.88	87.30
	SNN	CNN	Uni	Sigma-Delta LIF	Sigma-Delta	SLAYER	7014.45	90.62
	SNN	MLP	多	CUBA-LIF	速率编码	引导	3934.12	23.05
	SNN	MLP	Uni	CUBA-LIF	速率编码	Bootstrap	4009.93	26.46
	SNN	CNN	多	CUBA-LIF	速率编码	Bootstrap	6703.01	26.09
	SNN	CNN	Uni	CUBA-LIF	评分编码	Bootstrap	6579.49	25.99

表 17 Loihi 平台上高效且性能优化的 SNNs 的最佳延迟选择

模型	延迟=1	延迟=2	lag=3	lag=4	lag=5	lag=6	lag=7	lag=8	lag=9	lag=10	lag=11	lag=12
ANN-LSTM-多变量 (nRMSE)	0.064	0.048	0.047	0.047	0.047	0.047	0.047	0.047	0.047	0.047	0.047	0.047
ANN-LSTM-多变量 (Loihi 上的功耗 [nJ])	201.34	222.16	243.00	263.80	940.46	3,967	4,216	4,465	4,714	4,963	5,212	5,460
SNN CNN多变量 (Σ - Δ LIF) (nRMSE)	0.063	0.049	0.048	0.048	0.049	0.048	0.048	0.049	0.049	0.048	0.076	0.048
SNN CNN 多变量 (Σ - Δ LIF) (Power Consumption onLoihi [nJ])	6.24	9.36	12.29	15.50	18.83	21.43	24.54	27.95	30.22	34.61	36.47	40.25
SNN CNN 单变量 (CUBA-LIF) (nRMSE)	0.910	0.067	0.057	0.057	0.057	0.058	0.057	0.057	0.058	0.057	0.057	0.057
SNN CNN 单变量 (CUBA-LIF) (在 Loihi 上的功耗[nJ])	5.25	8.91	10.29	10.58	11.59	12.06	13.33	14.38	10.74	14.62	11.04	14.48

支持全球低碳目标和区域能源独立。实验数据强调了 SNN 在降低计算开销和提升与神经形态硬件兼容性方面的潜力,如表 12 所示,这表明这些网络在资源受限的应用中发挥着关键作用。我们的分析揭示了模型稀疏性、功耗效率和预测精度之间的权衡关系。这为网络设计提供了一种平衡方法,可能为该领域的未来发展提供指导。

为基于本研究发现,提出了几个未来研究方向。首先,探索结合 ANNs 和 SNN 优势的混合模型的设计与开发。此类混合架构可能利用 ANNs 的高精度和 SNN 的能效,在两个指标上均可能实现更优性能。其次,改进 SNN 的学习算法仍是一个开放性挑战。研究先进的训练技术和优化方法可能增强 SNN 的收敛性和泛化能力,使其更适合复杂的预测任务。第三,将本研究开发的方法论应用于太阳能辐射预测以外的其他领域,可以展示 SNN 的通用性和鲁棒性。这种方法可能受益于风能预测、智能电网负荷预测,甚至非能源相关的时间序列预测任务。此外,在 Intel 的 Loihi 等神经形态硬件平台上进行进一步实验,可以为 SNN 在实际应用中的部署和可扩展性提供实用见解。探索硬件-软件协同设计策略也可能优化 SNN 在此类平台上的性能。最后,尽管本研究使用 ARIMA 模型作为评估 ANNs 和 SNN 预测性能的基准,但未来的研究可以结合更高级的统计模型或集成方法,以提供更全面的比较并进一步验证神经网络方法的优势。

总之,将 SNNs 应用于太阳能光伏预测领域,对能源系统而言是一项变革性的进步,特别是在政治和经济敏感地区。通过利用 SNNs 的独特能力和持续创新神经网络技术,我们可以更好地应对可持续能源发展中的复杂挑战。

作者贡献 Bahgat Ayasi 参与了资源、软件、方法、数据管理、研究和写作——初稿, Iago X. Vázquez 贡献了资源和研究。Angel M. Garcia-Vico 参与了写作——审阅与编辑、写作——初稿、验证、监督、软件、资源、方法、研究、资金获取、形式分析、概念化。Cristobal J. Carmona 进行了写作——审阅与编辑、写作——初稿、可视化、验证、监督、软件、资源、项目管理、方法、研究、资金获取、概念化。Mohammed Saleh 负责资源的形式分析。

资助 本研究得到了科学创新部通过项目 PID2023-149511OB-I00 的支持

数据可用性 本研究使用的太阳能辐射和气象参数实验数据集可在国家太阳能辐射数据库 (NSRDB) 中公开获取。可通过以下链接访问: <https://nsrdb.nrel.gov/data-viewer>。

声明

利益冲突 所有作者均未声明存在潜在利益冲突

参考文献

1. Hamada S, Ghodieh A (2021) 西岸地区 (巴勒斯坦) 太阳能潜力的地理信息制图信息系统。论文应用地理学 7(3):256–273。 <https://doi.org/10.1080/23754931.2020.1870540>
2. 联合国: 17 个目标。 <https://sdgs.un.org/goals>。访问时间: 2024-01-15 (2015)

3. Omar MA, Mahmoud MM (2018) Grid connected pv home systems in palestine: a review on technical performance, effects and economic feasibility. *Renew Sustain Energy Rev* 82:2490–2497. <https://doi.org/10.1016/j.rser.2017.09.008>
4. Nassar YF, Alsadi SY (2019) Assessment of solar energy potential in gaza strip-palestine. *Sustain Energy Technol Assess* 31:318–328. <https://doi.org/10.1016/j.seta.2018.12.010>
5. Fan Z, Yan Z, Wen S (2023) Deep learning and artificial intelligence in sustainability: A review of sdgs, renewable energy, and environmental health. *Sustainability* 15(18):13493. <https://doi.org/10.3390/su151813493>
6. Khatib T, Bazyan A, Assi H, Malhis S (2021) Palestine energy policy for photovoltaic generation: current status and what should be next? *Sustainability (Switzerland)* 13(5):1–19. <https://doi.org/10.3390/su13052996>
7. Biancardi A, D'Adamo I, D'Amore F, Moretti R (2024) Prosumers as drivers of sdg7 in palestine: net-benefit analysis of grid-connected photovoltaic systems. *Utilities Policy* 87:101730. <https://doi.org/10.1016/j.jup.2024.101730>
8. Natsheh EM (2016) Power generation of solar pv systems in palestine. *Appl Solar Energy* 52:193–196. <https://doi.org/10.3103/S0003701X16030105>
9. Said N, Alsamamra H (2019) An overview of green buildings potential in palestine. *Int J Sustain Green Energy* 8(2): 11. <https://doi.org/10.11648/j.ijrse.20190802.11>
10. Rohde F, Gossen M, Wagner J, Santarius T (2021) Sustainability challenges of artificial intelligence and policy implications. *Ökologisches Wirtschaften-Fachzeitschrift* 36(O1):36–40. <https://doi.org/10.1007/s00506-021-00748-3>
11. Lohn AJ, Musser M (December 2021) Ai and compute: How much longer can computing power drive artificial intelligence progress? Technical report, Center for Security and Emerging Technology. <https://doi.org/10.51593/2021CA009>. <https://cset.georgetown.edu/wp-content/uploads/CSET-2021-CA009-AI-and-Compute.pdf>
12. Pachot A, Patissier C (2023) Toward sustainable artificial intelligence: An overview of environmental protection uses and issues. *Green and Low-Carbon Economy* 00(00), 1–8 <https://doi.org/10.47852/bonviewGLCE3202608>
13. Energy Sector Management Assistance Program: Global Photovoltaic Power Potential by Country. World Bank. Available online: <https://doi.org/10.1596/34102> (2020). <https://doi.org/10.1596/34102>
14. Imamkulieva E (2022) In: Name, E. (ed.) *Clean Energy in the Arab Countries*, pp. 58–72. Monograph Compiler Publications, Publisher Location
15. Ibrahim IA (2023) Energy transition and sustainable development goal 7: a legal analysis in the context of the arab world. *J World Energy Law Bus* 16(2):77–90. <https://doi.org/10.1080/23754931.2020.1870540>
16. Chodakowska E, Nazarko J, Nazarko Rabayah HS, Abende RM, Alawneh R (2023) Arima models in solar radiation forecasting in different geographic locations. *Energies* 16(13):5029. <https://doi.org/10.3390/en16135029>
17. Braik A, Makhalfih A, Hamid ASA, Sopian K, Ibrahim A (2022) Impact of photovoltaic grid-tied systems on national grid power factor in palestine. *AIMS Energy* 10(2):236–253. <https://doi.org/10.3934/energy.2022013>
18. Yang D, Jirutitijaroen P, Walsh WM (2012) Hourly solar irradiance time series forecasting using cloud cover index. *Sol Energy* 86(12):3531–3543. <https://doi.org/10.1016/j.solener.2012.07.029>
19. Alsharif MH, Younes MK, Kim J (2019) Time series arima model for prediction of daily and monthly average global solar radiation: The case study of seoul, south korea. *Symmetry* 11(2):240. <https://doi.org/10.3390/sym11020240>
20. Zamani Sabzi H, King JP, Abudu S (2017) Developing an intelligent expert system for streamflow prediction, integrated in a dynamic decision support system for managing multiple reservoirs: A case study. *Expert Syst Appl* 83:145–163. <https://doi.org/10.1016/j.eswa.2017.04.039>
21. Freeman BS, Taylor G, Gharabaghi B, Thé J (2018) Forecasting air quality time series using deep learning. *J Air Waste Manag Assoc* 68(8):866–886. <https://doi.org/10.1080/10962247.2018.1459956>
22. Zafirakis D, Tzanes G, Kaldellis JK (2019) Forecasting of wind power generation with the use of artificial neural networks and support vector regression models. *Energy Proc* 159:509–514. <https://doi.org/10.1016/j.egypro.2018.12.007>
23. Lara-Benítez P, Carranza-García M, Riquelme JC (2021) An experimental review on deep learning architectures for time series forecasting. *Int J Neural Syst* 31(03):2130001. <https://doi.org/10.1142/s0129065721300011>
24. Strubell E, Ganesh A, McCallum A (2020) Energy and policy considerations for modern deep learning research. *Proc AAAI Conf Artif Intell* 34:13693–13696
25. Lacoste A, Luccioni A, Schmidt V, Dandres T (2019) Quantifying the carbon emissions of machine learning. *arXiv preprint arXiv:1910.09700*
26. Schliebs S, Kasabov N (2013) Evolving spiking neural network-a survey. *Evol Syst* 4(2):87–98. <https://doi.org/10.1007/s12530-013-9074-9>
27. Maass W (1997) Networks of spiking neurons: the third generation of neural network models. *Neural Netw* 10(9):1659–1671
28. Ghosh-Dastidar S, Adeli H (2009) Spiking neural networks. *Int J Neural Syst* 19(04):295–308. <https://doi.org/10.1142/s0129065709002002>
29. Paugam-Moisy H, Bohtë SM (2012) Computing with Spiking Neuron Networks, pp. 335–376. https://doi.org/10.1007/978-3-540-92910-9_10
30. Kulkarni S, Simon SP, Sundareswaran K (2013) A spiking neural network (snn) forecast engine for short-term electrical load forecasting. *Appl Soft Comput* 13(8):3628–3635. <https://doi.org/10.1016/j.asoc.2013.04.007>

31. Reid D, Hussain AJ, Tawfik H (2014) Financial time series prediction using spiking neural networks. *PLoS ONE* 9(8):103656. <https://doi.org/10.1371/journal.pone.0103656>
32. Sun G, Chen T, Wei Z, Sun Y, Zang H, Chen S (2016) A carbon price forecasting model based on variational mode decomposition and spiking neural networks. *Energies* 9(1):54. <https://doi.org/10.3390/en9010054>
33. Zhang A, Zhu W, Li J (2019) Spiking echo state convolutional neural network for robust time series classification. *IEEE Access* 7:4927–4935. <https://doi.org/10.1109/ACCESS.2018.2887354>
34. Fang H, Shrestha A, Qiu Q (2020) Multivariate time series classification using spiking neural networks. In: 2020 international joint conference on neural networks (IJCNN), pp. 1–6. <https://doi.org/10.1109/IJCNN48605.2020.9206751>. IEEE
35. Matenczuk K, Kozina A, Markowska A, Czerniachowska K, Kaczmarczyk K, Golec P, Hernes M, Lutosławski K, Kozierkiewicz A, Pietranik M, Rot A, Dyvak M (2021) Financial time series forecasting: Comparison of traditional and spiking neural networks. *Proc Comput Sci* 192:5023–5029. <https://doi.org/10.1016/j.procs.2021.09.280>
36. González Sopeña JM, Pakrashi V, Ghosh B (2022) A spiking neural network based wind power forecasting model for neuromorphic devices. *Energies* 15(19):97256. <https://doi.org/10.3390/en15197256>
37. Intel's Neuromorphic Computing Lab: Lava: A Software Framework for Neuromorphic Computing. <http://lava-nc.org> and <https://github.com/lava-nc/lava>. Accessed January 1, 2024 (2021)
38. Lai CS, Zhong C, Pan K, Ng WWY, Lai LL (2021) A deep learning based hybrid method for hourly solar radiation forecasting. *Expert Syst Appl* 177:114941. <https://doi.org/10.1016/j.eswa.2021.114941>
39. Box GE, Jenkins GM, Reinsel GC, Ljung GM (2015) Time series analysis: forecasting and control. Wiley, Hoboken, NJ
40. Ervural BC, Beyca OF, Zaim S (2016) Model estimation of arma using genetic algorithms: a case study of forecasting natural gas consumption. *Proc Soc Behav Sci* 235:537–545. <https://doi.org/10.1016/j.sbspro.2016.11.010>
41. Cayir Ervural B, Ervural B (2018) Improvement of grey prediction models and their usage for energy demand forecasting. *J Intell Fuzzy Syst* 34(4):2679–2688
42. Hochreiter S, Schmidhuber J (1997) Long short-term memory. *Neural Comput* 9(8):1735–1780
43. Jebb AT, Tay L (2016) Introduction to time series analysis for organizational research: methods for longitudinal analyses. *Organ Res Methods* 20(1):61–94. <https://doi.org/10.1177/1094428116668035>
44. Siami-Namini S, Tavakoli N, Namin AS (2019) A comparative analysis of forecasting financial time series using ARIMA, LSTM, and BiLSTM. <http://export.arxiv.org/pdf/1911.09512>
45. Yan R, Liao J, Yang J, Sun W, Nong M, Li F (2021) Multi-hour and multi-site air quality index forecasting in beijing using cnn, lstm, cnn-lstm, and spatiotemporal clustering. *Expert Syst Appl* 169:114513. <https://doi.org/10.1016/j.eswa.2020.114513>
46. Radzi PNLM, Akhter MN, Mekhilef S, Shah NM (2023) Review on the application of photovoltaic forecasting using machine learning for very short-to long-term forecasting. *Sustainability* 15(4):2942. <https://doi.org/10.3390/su15042942>
47. Sharifzadeh M, Sikinioti-Lock A, Shah N (2019) Machine-learning methods for integrated renewable power generation: a comparative study of artificial neural networks, support vector regression, and gaussian process regression. *Renew Sustain Energy Rev* 108:513–538. <https://doi.org/10.1016/j.rser.2019.03.040>
48. Rana M, Koprinska I, Agelidis VG (2016) Univariate and multivariate methods for very short-term solar photovoltaic power forecasting. *Energy Convers Manag* 121:380–390. <https://doi.org/10.1016/j.enconman.2016.05.025>
49. Ahmed R, Sreeram V, Mishra Y, Arif MD (2020) A review and evaluation of the state-of-the-art in pv solar power forecasting: techniques and optimization. *Renew Sustain Energy Rev* 124:109792. <https://doi.org/10.1016/j.rser.2020.109792>
50. Lim B, Zohren S (2021) Time-series forecasting with deep learning: a survey. *Phil Trans R Soc A* 379(2194):20200209. <https://doi.org/10.1098/rsta.2020.0209>
51. Wang K, Qi X, Liu H (2019) A comparison of day-ahead photovoltaic power forecasting models based on deep learning neural network. *Appl Energy* 251:113315. <https://doi.org/10.1016/j.apenergy.2019.113315>
52. Ren X, Zhang F, Zhu H, Liu Y (2022) Quad-kernel deep convolutional neural network for intra-hour photovoltaic power forecasting. *Appl Energy* 319:119682. <https://doi.org/10.1016/j.apenergy.2022.119682>
53. Qing X, Niu Y (2018) Hourly day-ahead solar irradiance prediction using weather forecasts by lstm. *Energy* 148:461–468
54. Yang D (2019) A guideline to solar forecasting research practice: reproducible, operational, probabilistic or physically-based, ensemble, and skill (ropes). *J Renew Sustain Energy* 11(2):102
55. Yan K, Shen H, Wang L, Zhou H, Xu M, Mo Y (2020) Short-term solar irradiance forecasting based on a hybrid deep learning methodology. *Information* 11(1):32
56. Obiora CN, Hasan AN, Ali A, Alajarmeh N (2021) Forecasting hourly solar radiation using artificial intelligence techniques. *IEEE Canad J Elect Comput Eng* 44(4):497–508
57. Mukhtar M, Oluwasanmi A, Yimen N, Qinxu Z, Ukwuoma CC, Ezurike B, Bamisile O (2022) Development and comparison of two novel hybrid neural network models for hourly solar radiation prediction. *Appl Sci* 12(3):1435
58. Gerstner W, Kistler WM, Naud R, Paninski L (2014) Neuronal dynamics: from single neurons to networks and models of cognition. Cambridge University Press, Cambridge, UK

59. Gerstner W, Kistler WM (2002) Spiking Neuron Models: Single Neurons, Populations, Plasticity. Cambridge University Press, Cambridge, UK. <http://catdir.loc.gov/catdir/samples/cam031/2002067657.pdf>
60. Paugam-Moisy H (2006) Spiking neuron networks a survey. Technical report, EPFL-REPORT-83371. <http://publications.idiap.ch/downloads/reports/2006/paugam-idiap-rr-06-11.pdf>
61. Izhikevich EM (2003) Simple model of spiking neurons. *IEEE Trans Neural Netw* 14(6):1569–1572. <https://doi.org/10.1109/TNN.2003.820440>
62. Zambrano D, Bohte SM (2016) Fast and efficient asynchronous neural computation with adapting spiking neural networks. arXiv preprint [arXiv:1609.02053](https://arxiv.org/abs/1609.02053)
63. Brette R, Rudolph M, Carnevale T, Hines M, Beeman D, Bower JM, Destexhe A (2007) Simulation of networks of spiking neurons: a review of tools and strategies. *J Comput Neurosci* 23:349–398
64. Shrestha SB, Orchard G (2018) SLAYER: Spike layer error reassignment in time. <https://arxiv.org/pdf/1810.08646>
65. Davies M (2021) Taking neuromorphic computing to the next level with Loihi2. Intel Labs' Loihi
66. Lee C, Sarwar SS, Panda P, Srinivasan G, Roy K (2020) Enabling spike-based backpropagation for training deep neural network architectures. *Front Neurosci* 14:119. <https://doi.org/10.3389/fnins.2020.00119>
67. Diehl PU, Cook M (2015) Unsupervised learning of digit recognition using spike-timing-dependent plasticity. *Front Comput Neurosci* 9:99. <https://doi.org/10.3389/fncom.2015.00099>
68. Long L, Liu Q, Peng H, Yang Q, Luo X, Wang J, Song X (2022) A time series forecasting approach based on nonlinear spiking neural systems. *Int J Neural Syst* 32(08):204. <https://doi.org/10.1142/s0129065722500204>
69. Kulkarni S, Rajendran B (2018) Spiking neural networks for handwritten digit recognition-supervised learning and network optimization. *Neural Netw* 103:118–127. <https://doi.org/10.1016/j.neunet.2018.03.019>
70. Deng L, Wu Y, Hu X, Liang L, Ding Y, Li G, Zhao G, Li P, Xie Y (2020) Rethinking the performance comparison between snns and anns. *Neural Netw* 121:294–307. <https://doi.org/10.1016/j.neunet.2019.09.005>
71. Tan C, Šarlija M, Kasabov N (2021) Neurosense: short-term emotion recognition and understanding based on spiking neural network modelling of spatio-temporal eeg patterns. *Neurocomputing* 434:137–148. <https://doi.org/10.1016/j.neucom.2020.12.098>
72. Wang H, Xue W, Liu Y, Peng J, Jiang H (2020) Probabilistic wind power forecasting based on spiking neural network. *Energy* 196:117072. <https://doi.org/10.1016/j.energy.2020.117072>
73. Zhan G, Song Z, Fang T, Zhang Y, Le S, Zhang X, Kang X (2021) Applications of spiking neural network in brain computer interface. In: 2021 9th International Winter Conference on Brain-Computer Interface (BCI), pp. 1–6. <https://doi.org/10.1109/BCI51272.2021.9385361>. IEEE
74. Capizzi G, Sciuto GL, Napoli C, Woźniak M, Susi G (2020) A spiking neural network-based long-term prediction system for biogas production. *Neural Netw* 129:271–279. <https://doi.org/10.1016/j.neunet.2020.06.001>
75. Thangaraj VK, Nachimuthu DS, Francis VAR (2023) Wind speed forecasting at wind farm locations with an unique hybrid pso-alo based modified spiking neural network. *Energy Syst* 4:1–29. <https://doi.org/10.1007/s12667-023-00518-4>
76. Manna DL, Vicente-Sola A, Kirkland P, Bihl TJ, Di Caterina G (2023) An approach to time series forecasting with spiking neural networks. Preprint
77. Gao Y, Wang J, Guo L, Peng H (2024) Short-term photovoltaic power prediction using nonlinear spiking neural p systems. *Sustainability* 16(4):1709. <https://doi.org/10.3390/su16041709>
78. Sengupta M, Xie Y, Lopez A, Habte A, Maclaurin G, Shelby J (2018) The national solar radiation data base (nsrdb). *Renew Sustain Energy Rev* 89:51–60
79. Guo W, Fouda ME, Eltawil AM, Salama KN (2021) Neural coding in spiking neural networks: a comparative study for robust neuromorphic systems. *Front Neurosci* 15:638474. <https://doi.org/10.3389/fnins.2021.638474>
80. Nair MV, Indiveri G (2019) An ultra-low power sigma-delta neuron circuit. In: 2019 IEEE International Symposium on Circuits and Systems (ISCAS), pp. 1–5. IEEE
81. Kim Y, Park H, Moitra A, Bhattacharjee A, Venkatesha Y, Panda P (2022) Rate coding or direct coding: Which one is better for accurate, robust, and energy-efficient spiking neural networks? In: 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pp. 71–75. IEEE
82. Guo W, Fouda ME, Eltawil AM, Salama KN (2021) Neural coding in spiking neural networks: a comparative study for robust neuromorphic systems. *Front Neurosci* 15:638474
83. Pan Z, Wu J, Zhang M, Li H, Chua Y (2019) Neural population coding for effective temporal classification. In: 2019 International Joint Conference on Neural Networks (IJCNN), pp. 1–8. IEEE
84. Corporation N (2023) NVIDIA System Management Interface. <http://developer.download.nvidia.com/compute/DCGM/docs/nvidia-smi-367.38.pdf>. Accessed: 20 February
85. Liu L, Jiang H, He P, Chen W, Liu X, Gao J, Han J (2019) On the variance of the adaptive learning rate and beyond. arXiv preprint [arXiv:1908.03265](https://arxiv.org/abs/1908.03265)
86. Kucik AS, Meoni G (2021) Investigating spiking neural networks for energy-efficient on-board ai applications: A case study in land cover and land use classification. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 2020–2030
87. Research AB (2024) KerasSpiking - Estimating model energy. <https://www.nengo.ai/keras-spiking/examples/model-energy.html>. Last accessed on 12/04/2024

88. Ali HAH, Dabbous A, Ibrahim A, Valle M (2023) Assessment of recurrent spiking neural networks on neuromorphic accelerators for naturalistic texture classification. In: 2023 18th Conference on Ph. D Research in Microelectronics and Electronics (PRIME)
89. Herbozo Contreras LF, Huang Z, Yu L, Nikpour A, Kavehei O (2024) Biological plausible algorithm for seizure detection: Toward ai-enabled electroceuticals at the edge. *APL Machine Learning* 2(2)
90. Degnan B, Marr B, Hasler J (2015) Assessing trends in performance per watt for signal processing applications. *IEEE Trans Very Large Scale Integr VLSI Syst* 24(1):58–66
91. Davies M, Srinivasa N, Lin TH, Chinya G, Cao Y, Choday SH, Dimou G, Joshi P, Imam N, Jain S et al (2018) Loihi: a neuromorphic manycore processor with on-chip learning. *IEEE Micro* 38(1):82–99. <https://doi.org/10.1109/MM.2018.112130359>
92. Zhu RJ, Wang Z, Gilpin L, Eshraghian JK (2024) Autonomous driving with spiking neural networks. *ArXiv arXiv:2405.19687*
93. Vidya Wicaksana Putra R, Shafique M (2020) FSpINN: An Optimization Framework for Memory-and Energy-Efficient Spiking Neural Networks. *arXiv e-prints*, [arXiv:2007.00000](https://arxiv.org/abs/2007.00000)
94. Yao M, Zhao G, Zhang H, Hu Y, Deng L, Tian Y, Li G (2023) Attention spiking neural networks. *IEEE Trans Pattern Anal Mach Intell* 45(8):9393–9410
95. Han S, Mao H, Dally WJ (2015) Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding. *arXiv preprint arXiv:1510.00149*
96. Pfeiffer M, Pfeil T (2018) Deep learning with spiking neurons: opportunities and challenges. *Front Neurosci* 12:409662. <https://doi.org/10.3389/fnins.2018.409662>
97. Roy K, Jaiswal A, Panda P (2019) Towards spike-based machine intelligence with neuromorphic computing. *Nature* 575(7784):607–617. <https://doi.org/10.1038/s41586-019-1677-2>
98. Davies M, Wild A, Orchard G, Sandamirskaya Y, Guerra GAF, Joshi P, Rusbud SR (2021) Advancing neuromorphic computing with loihi: a survey of results and outlook. *Proc IEEE* 109(5):911–934. <https://doi.org/10.1109/JPROC.2021.3058954>

出版者注 Springer Nature 对已发表的地图中的管辖权主张以及机构隶属关系保持中立。

根据与作者或其他权利人签订的出版协议，Springer Nature 或其许可方（例如一个学会或其他合作伙伴）拥有本文的专有权利；作者自存已接受的本文手稿版本完全受该出版协议和适用法律的条款约束。

作者与隶属机构

Bahgat Ayasi^{1,7}  · 伊阿古 X. 瓦兹奎兹²  · 穆罕默德·萨利赫³  · Angel M. 加西亚-维科^{4,5}  · Cristóbal J. Carmona^{4,5,6} 

& Bahgat Ayasi

ba000034@red.ujaen.es

Iago X. Vázquez

ixvazquez@itcl.es

穆罕默德·萨利赫

msaleh@pass.ps

安赫尔·M·加西亚-维科

agvico@ujaen.es

克里斯托瓦尔·J·卡莫纳

ccarmona@ujaen.es

- ¹ 计算机科学系, Jaén大学, Las Lagunillas校区, 23071 Jaén, 安达卢西亚, 西班牙
- ² ITCL科技中心, 09001 Burgos, 西班牙
- ³ 信息技术中心, Al-Istiqlal大学, 杰里科, 巴勒斯坦
- ⁴ 安达卢西亚数据科学与计算智能研究所 (DaSCI), Jaén大学, E-23071 Jaén, 西班牙
- ⁵ 计算机科学系, Jaén大学, E-23071 Jaén, 西班牙
- ⁶ 莱斯特大学药学院, 德蒙福特大学, LE1 7RH 莱斯特, 英国
- ⁷ 计算机科学系, 阿拉伯美国大学 (AAUP), 240, 杰宁, 巴勒斯坦