

OPEN

使用机器学习预测发光太阳能聚光器的效率用于太阳能收集

Rute A. S. Ferreira^{1*}, Sandra F. H. Correia², Lianshe Fu¹, Petia Georgieva^{2,3,4}, Mario Antunes^{2,3} & Paulo S. André^{5*}

建筑一体化光伏 (BIPV) 是太阳能领域的一项新兴技术。它涉及利用光收集和转换材料, 通过发光太阳能聚光器将传统窗户转化为能量发生器。本研究调查了机器学习 (ML) 在推进光学材料设计基础理解方面的应用。通过利用可获取的光致发光测量, ML模型估计光学特性, 简化了开发新型材料的过程, 为传统方法提供了一种具有成本效益和效率的替代方案, 并促进了竞争性材料的筛选。回归和聚类方法被用于估计光学转换效率和功率转换效率。回归模型实现了10%的平均绝对误差 (MAE), 这表明在可能的值范围内具有10%的精度。回归和聚类模型均显示出高度的一致性, 具有最小的7%MAE, 突出了ML在预测BIPV用发光材料的光学特性方面的有效性。

关键词 发光太阳能聚光器, 机器学习, 聚类, 回归

基于化学或材料成分从已产生或发表的实验数据预测晶体结构的需求仍然是一个巨大的挑战^{1,2}。发现新材料或具有新性能的新材料的传统方法, 如实验室实验, 具有长期开发周期和高成本³。机器学习 (ML) 算法是解决这一问题的新的有前景的工具, 为管理和从海量数据中提取有价值的见解开辟了可能性⁴。将ML应用于材料科学是较新的⁵, 重点在于自然界中的基本模型, 同时也可以将ML用作小型低维数据集的简单拟合程序¹。

在过去十年中, ML的进展极大地影响了整个物理科学领域, 包括材料科学⁶, 其反映是创建材料基因组计划⁷作为加速材料开发和通过使用数据驱动方法合理设计材料的途径。其他研究报道了使用ML线性回归方法构建用于物理学和化学中材料的热力学性质的本征常数模型⁸, 以及数据中心方法用于聚合物晶体⁹, 药物科学¹⁰和金属成型过程的材料本构建模¹¹, 不久可能还会有更多重要的发展。此外, 最近收集的大量数据 (来自实验和模拟) 对于ML作为磷光设计工具的进步的重要性已经得到讨论¹²。因此, ML有望通过在这一快速发展的领域内发挥关键作用来进一步增强其在材料科学中的作用¹³。

在一个被气候变化、环境恶化和近期能源危机所笼罩的时代, 材料科学与工程领域获得了显著的相关性。这些领域通过材料的创新能力, 为缓解这些挑战的后果提供了关键途径, 使它们能够

¹CICECO-Aveiro材料研究所, 物理系, 阿威罗大学, 3810-193 阿威罗, 葡萄牙。 ²电信研究所, 阿威罗大学, 3810-193 阿威罗, 葡萄牙。 ³电子、电信与信息学系, 阿威罗大学, 3810-193 阿威罗, 葡萄牙。 ⁴阿威罗电子与信息工程研究所 (IEETA), 3800-193 阿威罗, 葡萄牙。 ⁵电气与计算机工程系和电信研究所, 高等技术学院, 里斯本大学, 1049-001 里斯本, 葡萄牙。 *email: rferreira@ua.pt; paulo.andre@lx.it.pt

不仅预测、控制、增强材料的性能，还可持续制造、使用和回收¹⁴。光子学由于其迅猛发展和在光伏等行业的创新潜力，成为21世纪的主要使能技术之一，而光伏行业最近在建筑一体化光伏领域尤为突出，以应对能源需求并在建筑物中实现就地发电^{15,16}。

发光太阳能聚光器（LSCs）^{17,18}代表了一种将被动玻璃窗户转化为自给自足能源的潜力策略¹⁵。通过利用太阳能并将其转化为低能量的光子，这些光子能够在太阳能电池中发电，LSCs为能源生产提供了一种革命性的方法（图1a）¹⁵。本质上，一个LSC由一个波导——无论是平面还是光纤——组成，其中填充了光学活性中心。这些中心吸收太阳光子，然后将其转化为低能量的光子。在全内反射的引导下，这些光子被导向波导边缘沿线的光伏电池，并有效地转化为电能。值得注意的是，LSCs通过大面积设备利用太阳能辐射，仅需在窗户边缘使用少量光伏材料。根据当前的优值指标，预计每平方米的表面面积为0.05至0.1米²，可产生10瓦的输出值，为物联网（IoT）设备提供动力^{19–21}。这为考虑更大尺寸的窗户——通常用于住宅建筑，尺寸在平方米量级——打开了大门，这些窗户可以被视为由更小尺寸的LSC组成的集合，而不会影响电输出。

LSC性能的优化是一个复杂的任务，因为其工作原理涉及多个事件，例如光活性中心的发射、菲涅尔反射、表面散射、波导衰减、透射辐射、邻近中心的再吸收、非辐射弛豫以及逃逸锥内的发射¹⁵（图1a）。挑战包括设计能够将阳光塑形以应对地球太阳辐照度与光伏电池吸收之间不匹配的频谱转换器，因为典型的低成本硅太阳能电池在紫外光谱区域性能较低。此外，对于立面应用，LSC必须确保辐射的可见成分不被吸收以保持透明度，将剩余成分重定向到与PV最大吸收对齐的光谱区域。因此，我们提议使用机器学习算法进行光学材料领域的驱动研究，重点在于低功率激发，即漫反射阳光条件，如阴天，其中紫外光子相对于可见/NIR光子的相对强度高于晴空条件²²。




图1. 发光太阳能聚光器和光致发光特征。(a) 平面LSCs工作原理的示意图：(1) 光活性中心的发光，(2) 菲涅尔反射，(3) 表面散射，(4) 波导衰减，(5) 透射辐射，(6) 邻近中心的再吸收，(7) 非辐射弛豫，(8) 逃逸锥内的发光。(b) 在550 nm处监测、在360 nm处激发的发光碳点²⁰的水溶液的激发（蓝线）和发射（橙线）光谱。阴影区域表示AM1.5G太阳光谱光子通量（右y轴）；吸收峰（ A_p ）、峰值发射波长（ E_p ）、最小/最大吸收波长（ A_{min}/A_{max} ）和最小/最大发射波长（ E_{min}/E_{max} ）也标出。根据知识共享署名3.0许可协议（<https://creativecommons.org/licenses/by/3.0/>）²⁰授权改编。 A_{min} 设置为300 nm，因为在此波长以下太阳辐照度非常低（ $\sim 10^{-40}$ %的地球总太阳辐照度）且 E_{max} 对应发射光谱的高波长值，在该处强度与噪声水平存在显著偏差（ $> 5\%$ ）^{24,25}。

此处目标是讨论机器学习作为无大量实验测量的设备设计决策工具的宝贵资源，正如最近建议的那样²³。一个关键步骤是识别与性能相关的光致发光指标（例如吸收和发射光谱范围、量子产率、光稳定性），这些指标能够使结果（例如材料系列、浓度、制备方法）得到适当基准化^{24,25}。独立识别将允许影响基础研究，因为通常稳定性和光学性能由不同的研究领域解决，而工程师和行业可以同时结合两者，因为商业应用需要稳定性和高性能。

我们提出了使用基于经典的机器学习回归和聚类方法作为相关拟合程序，用于估计发光材料的潜在光学特性。研究表明， η_{opt} ，以及功率转换效率（PCE）可以从易于获取、可测量的光学特征（即吸收和发射光谱）中估计。对五种最典型应用的机器学习回归模型的比较研究，即梯度提升回归器（GBR）、线性回归、K-近邻回归器、随机森林回归器和XGBoost，表明它们的性能相似。在清理和去除数据异常值后，所提出的回归器的性能得到了进一步提高，这表明数据驱动方法对于估计新材料的光学特性具有很高的潜力，即使对于小规模数据集^{24,25}也是如此。

结果与讨论 数据记录

数据集包含来自其他地方的前260个条目的几个数值光学特征²⁴并显示在图2中。选定的数值特征是(i) 峰吸收波长 (A_p)，(ii) 最小吸收波长 (A_{min})，(iii) 最大吸收波长 (A_{max}) (iv) 峰发射波长 (E_p) (v) 最小发射波长 (E_{min})，(vi) 最大发射波长 (E_{max})，以及 (vii) 绝对发射量子产率 (η_{yield} 定义为样品吸收和发射光子数的比率)²⁵。为了说明每个实验参数的物理意义，图1b显示了所选材料的吸收和发射光谱。与吸收和发射带相关的参数特别重要，因为它们定义了自吸收，即吸收和发射光谱之间的重叠，这会导致再吸收损耗（例如，对于有机分子定义的大斯托克斯位移^{15,26}）。这一点已被指出是器件性能^{15,16,27–31}最关键方面之一，尽管在少数作品中^{25,27–29}可以量化。光稳定性也是LSC器件实际应用的一个关键参数。然而，由于这通常不在已发表的作品中报告，并且没有标准条件来执行或报告，因此在本研究中未将其作为特征包含。

两种与光学中心类型相关的分类特征（mat0 和 mat1）也被考虑在内，即有机染料（染料）、镧系离子（Ln）、量子点（QD）、碳点（CD）、纳米颗粒（NP）或处理特征（例如块状、纤维、溶液、薄膜），分别对应。表征 LSC 性能的品质因数 η_{opt} 是由输出光功率（ P_{out} ）与输入光功率（ P_{in} ）的比值以及 PCE 组成，PCE 考虑了入射到 LSC 的太阳能中有多少比例被转化为可用电能（补充信息中的 Eq. S1-S4）。表1展示了数据集的一个样本，说明了所报道的 LSC 的通用光学特征和性能光学特征，根据光学活性中心。

回归阶段

分析从对每个特征的数值分布的定量评估（图2）以及每对特征之间以及特征与估计输出变量之间的相互相关性的视觉检查（补充信息中的 Figs. 3 和 S1）开始，如“方法”部分所述。请注意，任何输入变量（预测因子）与预测输出之间都没有实质性的线性相关性。仅在部分特征之间观察到线性相关性，即 E_{max} vs. E_p 和 η_{opt} vs. PCE（图3）。光学特征之间的线性相关性可以通过关注典型的光致发光光谱高斯分布来解释，从而诱导 E_{max} 和 E_p 特征²³之间的相关性。 η_{opt} 与 PCE 之间的相关性是由于入射光子数量越多被转换（由 η_{opt} 量化），光伏电池中产生电子的概率就越大（由 PCE 量化）。值得注意的是，PCE 主要取决于用于制造光伏电池的半导体类型及其效率¹⁵。由于 90% 的数据中使用了基于硅的光伏电池²⁵，因此光学响应相似，因此 PCE 与 η_{opt} 线性相关性良好。

我们注意到，在 η_{opt} 方面的性能与光伏技术无关，因为它仅量化发射层的光谱转换，因此该参数可以使用机器学习算法预测，正如最近使用人工神经网络²³所展示的那样。只有使用其他基于半导体的技术（例如 GaAs、钙钛矿、CIGS—黄铜矿硒化物，CuInSe₂，有机敏感染料）获得的 PCE 值位于线性关联之外，因为这些材料与硅相比表现出不同的响应性。然而，研究表明，即使对于光伏技术非硅基的数据集，真实值与预测值之间的相关性也很高，这证明了该算法也适用于这些情况，考虑到误差。

表2和表3分别列出了 PCE 和 η_{opt} 的估计值，考虑了 6、7 或 9 个预测器（输入变量），这些预测器用于在所有可用数据（包括异常值）或去除异常值后训练模型的情况（详见“方法”部分）。误差分布以小提琴图的形状表示，这些小提琴图提供了 5 个回归模型（详见“方法”部分）的不同输入特征，并显示在补充信息中的图 S2–S5。在每个场景中，用于拟合回归模型的数据集因丢弃了缺失值的样本而有所不同。例如，在具有 6 个输入特征 (A_p , A_{min} , A_{max} , E_p , E_{min} , E_{max}) 的基线模型中，仅考虑了 PCE 或 η_{opt} 有可用值的行。




图2。数据集—数值和分类特征。光学中心类型 (mat0)、有机染料 (dye)、镧系离子 (Ln)、量子点 (QD)、碳点 (CD)、纳米粒子 (NP) 的直方图和值分布; (a) 处理特征 (mat1)、块状、纤维、溶液、薄膜、(c) 峰值吸收波长 (A_p)、(d) 最小吸收波长 (A_{min})、(e) 最大吸收波长 (A_{max}) (f) 峰值发射波长 (E_p) (g) 最小发射波长 (E_{min})、(h) 最大发射波长 (E_{max})、(i) 绝对发射量子产率 (η_{yield})、(j) 光学转换效率 (η_{opt})，以及(k) 功率转换效率 (PCE)。

被考虑。对于具有7 (A_p , A_{min} , A_{max} , E_p , E_{min} , E_{max} , η_{yield}) 或9个预测器的场景 (A_p , A_{min} , A_{max} , E_p , E_{min} , E_{max} , η_{yield} , mat0, mat1)，仅考虑了具有可用 η_{yield} 和 PCE 或 η_{opt} 的行。这些限制是由于监督学习方法，其中模型使用完整的输入-输出信息进行拟合。

与误差相关的指标，包括平均绝对误差 (MAE) 和均方误差 (MSE)，表明浅层学习模型仅基于吸收和发射特征 (6个输入变量的情况) 即可对 PCE 和 η_{opt} 进行相当准确的估计。当额外包含 η_{yield} 以及材料特性 (mat0 和 mat1) 等特征时，观察到边际正向效应。这些结果表明，性能主要由吸收光谱 (与 AM1.5 的重叠) 和发射光谱 (与光伏电池工作范围的重叠) 决定。

除线性回归 (未去除异常值的情况) 外，其他回归方法都收敛到相似的性能指标，这些指标依赖于所得结果的置信度。由于 PCE 值在 (0–10) 区间内变化 (见图 2k)，大多数情况下，MAE 在 1 或以下，对应于最大 10% 的误差。

光学中心		通用光学特性							性能光学特性	
类型 (mat0)	加工 (mat1)	吸收			排放					
		A_p (nm)	A_{min} (nm)	A_{max} (nm)	E_p (nm)	E_{min} (nm)	E_{max} (nm)	η_{yield} (%)		
Dye ³⁶	Film	770	300	800	775	700	950	16	1.5	–
Dye ²¹	Bulk	665	250	700	670	600	750	12	3.7	0.10
Ln ³⁷	纤维	370	300	450	615	570	710	89	0.7	–
染料 ³⁷		560	300	600	580	550	700	95	2.1	–
染料 ³⁷		780	300	750	730	650	850	21	0.5	–
Ln ³⁷		370	300	450	615	570	710	89	–	0.08
染料 ³⁷		560	300	600	580	550	700	95	–	0.21
QD ³⁸	Bulk	580	500	620	630	590	700	10	–	2.10
染料 ³⁹		498	300	700	580	520	700	30	6.88	0.27
染料 ⁴⁰		569	350	600	595	550	750	61	2.58	–
染料 ⁴¹		488	300	500	510	450	600	51	3.3	0.35
CD ²⁰	Film	491	250	520	520	500	700	82	5.43	0.18
染料 ¹⁹	Bulk	660	480	680	665	600	800	31	2.65	0.210

表 1. 表格数据集^{24,25} 的示例，显示峰值吸收波长 (A_p)、吸收光谱范围的最小波长 (A_{min})、吸收光谱范围的最大波长 (A_{max})、峰值发射波长 (E_p)、发射光谱范围的最小波长 (E_{min})、发射光谱范围的最大波长 (E_{max})、量子产率 (η_{yield})、光学转换效率 (η_{opt}) 和根据光学活性中心类型和工艺报告的 LSCs 的功率转换效率 (PCE)




图 3. 特征相关性。六种数值输入特征之间的成对相关性，以及它们与估计输出 (PCE, η_{opt}) 之间的相关性。

回归模型	异常值	评估指标								
		MAE			MSE			R2		
		输入								
		6 ^a	7 ^b	9 ^c	6 ^a	7 ^b	9 ^c	6 ^a	7 ^b	9 ^c
线性	未移除	1.21	1.33	1.29	2.03	3.27	2.94	0.19	0.00	0.15
	已移除	0.98	1.04	0.87	1.84	1.56	1.44	0.12	0.30	0.20
K近邻	未移除	1.05	0.91	0.98	2.23	2.55	2.39	0.11	0.23	0.31
	移除	0.72	0.82	0.74	1.13	1.10	1.27	0.46	0.24	0.30
随机森林	未移除	0.94	0.91	1.03	1.66	2.02	2.43	0.34	0.39	0.29
	移除	0.70	0.63	0.62	1.01	0.95	0.74	0.52	0.57	0.59
梯度提升	未移除	1.08	0.93	1.03	2.45	2.56	2.60	0.02	0.22	0.24
	移除	0.85	0.84	0.49	1.58	1.79	0.60	0.24	0.19	0.67
XGBoost	未移除	1.01	1.01	1.23	1.56	2.55	3.20	0.38	0.22	0.07
	已移除	0.80	0.77	0.61	1.30	1.75	1.01	0.38	0.21	0.44

表2. 使用回归模型进行PCE估计（使用K折交叉验证实验的验证样本的结果）。a $\eta_{yield}^{p \min \max p \min \max p \min \max p \min \max}$ 输入特征 (A, A, A, E, E, E), b 输入特征 (A, A, A, E, E, E), c 数值和分类特征 (A, A, A, E, E, E, , mat mat)。

回归模型	异常值	评估指标								
		MAE			MSE			R2		
		输入								
		6 ^a	7 ^b	9 ^c	6 ^a	7 ^b	9 ^c	6 ^a	7 ^b	9 ^c
线性	未移除	4.11	4.33	3.15	32.50	38.71	20.75	-0.08	0.05	0.49
	移除	1.46	1.25	1.16	2.81	2.32	2.13	-0.02	0.03	0.11
K-nearest neighbors	未移除	2.38	2.98	2.93	12.45	23.43	22.28	0.58	0.43	0.46
	已移除	1.12	0.98	1.11	2.12	1.64	1.95	0.23	0.31	0.18
Random forest	未移除	4.20	3.47	4.43	32.08	29.89	42.65	-0.07	0.27	-0.04
	移除	1.24	1.17	1.20	2.19	2.54	2.43	0.20	-0.06	-0.02
梯度提升	未移除	3.43	3.63	4.41	22.79	35.46	52.49	0.24	0.13	-0.28
	已移除	1.34	1.51	1.50	2.62	3.50	3.86	0.05	-0.47	-0.62
XGBoost	未移除	3.66	3.29	5.00	31.29	33.77	58.79	-0.04	0.17	-0.44
	移除	1.47	1.29	1.15	2.94	2.94	2.62	-0.07	-0.23	-0.10

表3. η_{opt} 回归模型估计（K折交叉验证实验的验证样本结果）。a $\eta_{yield}^{p \min \max p \min \max p \min \max p \min \max}$ 输入特征 (A, A, A, E, E, E), b 输入特征 (A, A, A, E, E, E), c 调用数值和分类特征 (A, A, A, E, E, E, , mat mat)。

在PCE估计中的误差，考虑到估计基于标准光致发光易于获取的测量结果，是一个相当可接受的结果。关于 η_{opt} 在(0-50)区间内的变化（见图2j），以及大多数情况下MAE小于4，可以得出类似的结论。尽管模型表现出同等竞争力，但随机森林（RF）回归器（去除异常值后）略微优于其他模型。类似的结果已被报道，使用RF估计数据不确定性³²。

我们得出结论，在数据不确定性的情况下，在不同数据副本上训练决策树并行模型集合是有利于输出更稳健的估计的。在所有模型中，通过去除异常值，估计精度得到提高（补充信息中的图S2-S5）。然而，应该注意的是，去除异常值可能会阻碍模型估计高水平的PCE和 η_{opt} ，因为它们被截断了。请注意，表2和表3中的结果涉及来自验证集（完整数据集的10%）的测试样本，这是一个相对较小的样本数量。因此，由确定系数（R²）指标测量的解释方差不会表现出很高的值。

聚类阶段

K-Means聚类算法用于对回归模型进行进一步验证。目标是分离数据样本到连贯的簇中，并从每个簇内的可用测量值中估计缺失的PCE和 η_{opt} （有关详细信息，请参见“方法”部分）。图4说明了各种聚类指标在最佳簇数方面缺乏明确的一致性。然而，五个簇似乎是他们建议的平均值，并且对于当前数据集大小是一个相关数量。因此，K-Means设置为K=5个簇。在第一步中，每个样本根据样本与K个簇质心之间的最小距离被分配到最近的簇。接下来，对于PCE或 η_{opt} 值未知的样本，确定了n个（在我们的实验中n η_{opt} ）具有可用PCE和=5的最近样本。然后，缺失的PCE和 η_{opt} 被估计为最近样本的可用测量值的中位数。




图4. 聚类质量。不同聚类数量（从1到20个聚类）的聚类质量指标：(a) 肘部法，(b) Calinski-Harabasz，(c) Davies-Bouldin，(d) Silhouette，和 (e) BIC。红色点表示每个指标建议的最佳聚类数量。

samples（在我们的实验中 $n=3$ ）具有可用PCE和 η_{opt} ，被识别出来。然后，缺失的PCE和 η_{opt} 被估计为最近样本的可用测量值的中位数。

回归 vs. 聚类

基于聚类的估计（无监督方法）与回归模型（监督方法）的一致性被评估。尽管回归模型表现出相似的性能，但由于其简单性、无需损失函数优化以及需要选择的超参数较少，我们选择了K-最近邻来与K-均值聚类进行比较。

图5描绘了KNN回归模型和K-Means聚类提供的PCE估计与 η_{opt} 之间的平均绝对误差（MAE）小提琴图。对于相同场景（包括和不包括去除异常值），MSE和 R^2 指标也一并呈现。由于PCE值在(0–10)区间内（图2k），MAE等于0.65（未去除异常值）或0.60（已去除异常值）意味着K-means和KNN估计之间约6%的误差，这在两种方法之间总体上是可接受的差异。类似地， η_{opt} 值在(0–50)区间内（图2j），因此MAE等于2.43（未去除异常值）或2.95（已去除异常值）意味着小于7%的误差，这也是非常一致的结果。因此，回归和聚类两种方法之间的协议对于PCE和 η_{opt} 的估计都得到了很好的证明。




图5. 基于聚类的估计和KNN回归的MAE小提琴图，(a) η_{opt} 和 (b) PCE。相同场景的 MSE 和 R^2 指标（包括和排除异常值）。

所呈现的结果表明，回归模型在估计目标量时自然是一种更可靠的方法，尤其是在数据集相对较小时。如果估计变量的统计变异性有限且被数据充分覆盖，聚类是一种简单的方法来验证回归模型，也可以用作可行的替代方案。此外，我们的研究结果表明，始终有可能找到一种方法来增强数据，以提高模型的泛化能力。

在这项工作中，探索了机器学习技术在促进材料开发和优化方面的潜力。我们提出的研究问题是，如何仅使用易于获取的信息（如常规光致发光和关于光学活性中心的知识）来可靠地估计用于BIPV的发光材料的性能。我们提出了基于机器学习的理性设计两阶段。在第一阶段，通过应用回归模型估计材料数据集的光学性能特征（PCE和 η_{opt} ）。在这个阶段，光致发光测量 A_p , A_{min} , A_{max} , E_p , E_{min} , E_{max} 和 E_{max} 被确定为最合适的预测因子。我们的发现证实，一旦正确识别了最相关的特征，机器学习模型的选择就不那么关键了。五种回归方法表现出相似的性能，这进一步增强了我们对所提出的数据驱动方法的信心。回归模型的训练和验证及其超参数的选择遵循了标准的机器学习调优过程，即K折交叉验证和网格搜索。在第二阶段，我们应用了K均值聚类技术将材料分为连贯的组，并估计PCE和 η_{opt} 的缺失值，从而加强了第一阶段得出的结论。这项研究的主要收获是，通过结合监督和无监督机器学习技术提出的理性设计，是一种很有前景的方法，可以加快开发用于阳光收集和能量转换的新型发光材料。结合作为输入的光致发光特征和特别通用的机器学习方法，本工作为开发除光伏之外各种光子应用中的材料开辟了新的视角，在这些应用中，光致发光相关特征至关重要（例如照明和传感）。

方法

基于回归模型的监督学习

我们旨在建立实验数值特征与光学性能之间的可靠关系，因此为 η_{opt} 和PCE建立了独立的回归模型。还分析了特征重要性，并定义了最具判别性的特征。构建并调优了五个回归模型：线性回归、K-近邻、随机森林、梯度提升和XGBoost（详细信息见补充材料）。

图2中的特征分布显示了极端值，这些值与测量误差无关，因此被视为异常值。通常，回归模型会受到异常值的不利影响，因此进行了两次回归分析：构建回归模型时（i）使用所有可用值（不删除异常值），以及（ii）使用四分位距（IQR）方法过滤异常值后（详细信息见补充材料）。

由于数据集在光学性能 η_{yield} 、 η_{opt} 和PCE方面分别包含14%、24%和41%的缺失值，为了建立基线，我们仅使用六个没有缺失值的吸收和发射特征（ A_p 、 A_{min} 、 A_{max} 、 E_p 、 E_{min} 和 E_{max} ）评估了PCE和 η_{opt} 的可预测性。为应对数据集规模有限的问题，我们采用了浅层学习模型，并将数据集按90%和10%分割用于训练和测试。该分割针对回归问题进行了调整，因为它将目标变量分成多个区间，然后用于训练-测试分层过程。这确保了生成的分割在目标变量的数据分布上尽可能接近原始数据集。使用网格搜索来设置最佳模型超参数，并使用K折交叉验证（CV）进行训练子集（K折交叉验证也针对回归问题进行了调整）。由于估计的性能是连续变量，我们选择了三个评估指标：MAE、MSE和 R^2 。MAE衡量预测集中误差的平均幅度，计算为实际值与预测值之间平均绝对差，MSE则量化了预测值与实际值之间的平均平方差。MAE或MSE越小，模型的预测效果越好。最后， R^2 是一个统计指标，表示回归模型拟合数据的程度。它衡量了因变量中多少变化可以由自变量解释^{33–35}。

聚类方法

使用仅有的六个数值输入特征（ A_p 、 A_{min} 、 A_{max} 、 E_p 、 E_{min} 、 E_{max} ）对数据集进行聚类，用于分析这些特征中是否存在允许通过增强光学性能（更大的 η_{opt} 和PCE值）对材料进行聚类的模式。

第一步是选择相关的簇数量以理解数据。为此，我们应用了五种不同的指标来评估簇质量：Elbow、Calinski-Harabasz、Davies-Bouldin、Silhouette和贝叶斯信息准则（BIC）。每个指标从1到20个簇进行计算。Elbow方法是一种启发式方法，用于确定数据集中最相关的簇数量。它通过将解释的变异作为簇数量的函数进行绘制，并将曲线的拐点作为要使用的簇数量。Calinski-Harabasz指数奖励那些簇中心彼此远离，而簇成员与其各自的中心距离较近的聚类。Davies-Bouldin指数定义为每个簇与其最相似簇的平均相似度度量，其中相似度是簇内距离与簇间距离的比率。Silhouette分数计算一个对象与其簇相比其他簇的相似程度。Silhouette分数范围从-1到1，其中接近1的分数表示对象与其簇匹配良好，与邻近簇匹配较差。BIC是一种在有限模型集中进行模型选择的指标，因此具有最低BIC的模型是首选。

数据可用性

支持本研究发现的数据可在 figShare 上获取 (<https://doi.org/10.6084/m9.figshare.24903387.v1>)。

代码可用性

支持本研究发现代码可在 GitHub 上获取 (<https://github.com/mariolpantunes/sunlight-harvesting-energy-conversion>)。

收到: 2023年8月28日; 接受: 2024年2月15日

Published online: 20 February 2024

References

- Schmidt, J., Marques, M. R. G., Botti, S. & Marques, M. A. L. Recent advances and applications of machine learning in solid-state materials science. *NPJ Comput. Mater.* **5**, 83 (2019).
- Maddox, J. Crystals from first principles. *Nature* **335**, 201 (1988).
- Wang, A. Y. T. et al. Machine learning for materials scientists: An introductory guide toward best practices. *Chem. Mater.* **32**, 4954–4965 (2020).
- Dash, J. K., Sharma, M. & Dalapati, G. K. Chapter 12 - Machine learning approach for materials technologies. In *Energy Saving Coating Materials: Design, Process, Implementation and Recent Developments* (eds Dalapati, G. K. & Sharma, M.) 285–289 (Elsevier Inc., 2020).
- Rajan, K. Materials informatics. *Mater. Today* **8**, 38–45 (2005).
- Cai, J. Z., Chu, X., Xu, K., Li, H. B. & Wei, J. Machine learning-driven new material discovery. *Nanoscale Adv.* **2**, 3115–3130 (2020).
- Mueller, T., Kusne, A. G. & Ramprasad, R. Machine learning in materials science: Recent progress and emerging applications. In *Reviews in Computational Chemistry Vol. 29* (eds Parrill, A. L. & Lipkowitz, K. B.) 186–273 (Wiley, 2016).
- Fransson, E., Eriksson, F. & Erhart, P. Efficient construction of linear models in materials modeling and applications to force constant expansions. *NPJ Comput. Mater.* **6**, 135 (2020).
- Schottle, M., Tran, T., Oberhofer, H. & Retsch, M. Machine learning enabled image analysis of time-temperature sensing colloidal arrays. *Adv. Sci.* **10**, 2205512 (2023).
- Caseiro, A. R. et al. Human umbilical cord blood plasma as an alternative to animal sera for mesenchymal stromal cells in vitro expansion—A multicomponent metabolomic analysis. *PLoS One* **13**, e0203936 (2018).
- Lourenço, R., Andrade-Campos, A. & Georgieva, P. The use of machine-learning techniques in material constitutive modelling for metal forming processes. *Metals* **12**, 427 (2022).
- Behara, S., Rath, S. & Thomas, T. Machine learning (ML) as a tool for phosphor design: A perspective. *Mater. Lett.* **308**, 131061 (2022).
- Pilania, G. Machine learning in materials science: From explainable predictions to autonomous design. *Comp. Mater. Sci.* **193**, 110360 (2021).
- Ball, P. Materials innovation from quantum to global. *Nat. Mater.* **21**, 962–967 (2022).
- Ferreira, R. A. S., Correia, S. F. H., Monguzzi, A., Liu, X. & Meinardi, F. Spectral converters for photovoltaics—What's ahead. *Mater. Today* **33**, 105–121 (2020).
- Meinardi, F., Bruni, F. & Brovelli, S. Luminescent solar concentrators for building-integrated photovoltaics. *Nat. Rev. Mater.* **2**, 17072 (2017).
- Weber, W. H. & Lambe, J. Luminescent greenhouse collector for solar radiation. *Appl. Opt.* **15**, 2299–2300 (1976).
- Goetzberger, A. & Greubel, W. Solar-energy conversion with fluorescent collectors. *Appl. Phys.* **14**, 123–139 (1977).
- Correia, S. F. H. et al. Bio-based solar energy harvesting for onsite mobile optical temperature sensing in smart cities. *Adv. Sci.* **9**, 2104801 (2022).
- Correia, S. F. H. et al. Autonomous power temperature sensor based on window-integrated transparent PV using sustainable luminescent carbon dots. *Nanoscale Adv.* **5**, 3428–3438 (2023).
- Frias, A. R. et al. Sustainable luminescent solar concentrators based on organic-inorganic hybrids modified with chlorophyll. *J. Mater. Chem. A* **6**, 8712–8723 (2018).
- Li, Y. L., Sun, Y. J. & Zhang, Y. C. Luminescent solar concentrators performing under different light conditions. *Sol. Energy* **188**, 1248–1255 (2019).
- André, P. S., Dias, L. M. S., Correia, S. F. H., Carneiro Neto, A. N. & Ferreira, R. A. S. Artificial neural networks for predicting optical conversion efficiency in luminescent solar concentrators. *Sol. Energy* **268**, 112290 (2024).
- Ferreira, R. A. S. et al. A comprehensive dataset of photonic features on spectral converters in energy harvesting and conversion applications. figshare. Dataset. <https://doi.org/10.6084/m9.figshare.24903387.v1> (2023).
- Ferreira, R. A. S. et al. A comprehensive dataset of photonic features on spectral converters for energy harvesting. *Sci. Data* **11**, 50 (2024).
- Meinardi, F. et al. Large-area luminescent solar concentrators based on “Stokes-shift-engineered” nanocrystals in a mass-polymerized PMMA matrix. *Nat. Photonics* **8**, 392–399 (2014).
- Yang, C. C. et al. Impact of Stokes shift on the performance of near-infrared harvesting transparent luminescent solar concentrators. *Sci. Rep.* **8**, 16359 (2018).
- Yang, C. H. et al. High-performance near-infrared harvesting transparent luminescent solar concentrators. *Adv. Opt. Mater.* **8**, 1901536 (2020).
- Richards, B. S. & Howard, I. A. Luminescent solar concentrators for building integrated photovoltaics: Opportunities and challenges. *Energy Environ. Sci.* **16**, 3214–3239 (2023).
- Mazzaro, R. & Vomiero, A. The renaissance of luminescent solar concentrators: the role of inorganic nanomaterials. *Adv. Energy Mater.* **8**, 1801903 (2018).
- de Bruin, T. A. & van Sark, W. G. J. H. M. Optimising absorption in luminescent solar concentrators constraint by average visible transmission and color rendering index. *Front. Phys.* **10**, 856799 (2022).
- Zviaghynski, B. & Conduit, G. Unveil the unseen: Exploit information hidden in noise. *Appl. Intell.* **53**, 11966–11978 (2023).
- Al-Jarrah, O. Y., Yoo, P. D., Muhaidat, S., Karagiannidis, G. K. & Taha, K. Efficient machine learning for big data: A review. *Big Data Res.* **2**, 87–93 (2015).
- Antony, P. J., Manujesh, P. & Jnanesh, N. A. In *2016 IEEE International Conference on Recent Trends in Electronics, Information & Communication Technology (REICT)*, 69–73 (2016).
- Ferguson, A. L. Machine learning and data science in soft materials engineering. *J. Phys. Condens. Matter* **30**, 043002 (2018).
- Rondão, R. et al. High-performance near-infrared luminescent solar concentrators. *ACS Appl. Mater. Interfaces* **9**, 12540–12546 (2017).

37. Correia, S. F. H. *et al.* Large-area tunable visible-to-near-infrared luminescent solar concentrators. *Adv. Sustain. Syst.* **2**, 1800002 (2018).
38. Gallagher, S. J., Norton, B. & Eames, P. C. Quantum dot solar concentrators: Electrical conversion efficiencies and comparative concentrating factors of fabricated devices. *Sol. Energy* **81**, 813–821 (2007).
39. Frias, A. R. *et al.* Sustainable liquid luminescent solar concentrators. *Adv. Sustain. Syst.* **3**, 1800134 (2019).
40. Sadeghi, S 等人 环保高效的荧光蛋白太阳能聚光器 ACS 应用材料与界面 **11**, 8710–8716 (2019).
41. Carlos, C. P. A. 等. 基于光效稳定绿色荧光蛋白的环境友好型发光太阳能聚光器. *Green Chem.* **22**, 4943–4951 (2020).

致谢

这项工作得到了欧盟-下一代欧盟的支持，通过保加利亚共和国的国家复苏和韧性计划，项目编号 N0 BG-RRP-2.004-0005。这项工作由葡萄牙2020通过欧洲区域发展基金（ERDF）在CENTRO2020框架内资助，项目为PLANETa，CENTRO -01-0145-FEDER-181242，并在CICECO-阿威罗材料研究所（UIDB/50011/2020 & UIDP/50011/2020），电信研究所（FCT Ref. UIDB/50008/2020-UIDP/50008/2020），SOLPOWINS—太阳能智能窗户用于可持续建筑（PTDC/CTM-REF/4304/2020）的范围内获得资助，由国家资金通过FCT/MEC提供，并在适当情况下由FEDER在PT2020伙伴关系框架下通过欧洲区域发展基金（ERDF）在运营竞争力和国际化计划（POCI）的范围内共同资助。SFHC感谢FCT（2022.03740.CEECIND/CP1716/CT0006）。

作者贡献

R.A.S.F. 和 P.S.A. 参与了研究计划的制定、所有数据的获取、数据分析、结果讨论和文稿撰写。S.F.H.C. 和 L.F. 参与了数据获取、数据分析和文稿撰写。M.A. 和 P.G. 定义了结构的分布以用作训练数据，并制作和训练了机器学习模型。

利益冲突

作者声明没有利益冲突。

补充信息

补充信息 网络版包含可在 <https://doi.org/10.1038/s41598-024-54657-x> 获取的补充材料。

通讯和材料请求应寄至 R.A.S.F. 或 P.S.A.

复制和权限信息可在 www.nature.com/reprints 获得。

出版商注 Springer Nature 对已发表的地图中的管辖权主张和机构隶属关系保持中立。

开放获取 本文根据知识共享署名 4.0 国际许可协议授权，该协议允许在任何媒介或格式中使用、分享、改编、分发和复制，前提是向原作者（或）和来源提供适当的署名，提供指向知识共享许可协议的链接，并说明是否进行了修改。本文中的图像或其他第三方材料包含在本文的知识共享许可协议中，除非材料信用行另有说明。如果材料未包含在本文的知识共享许可协议中，并且您的预期使用受到法定法规的限制或超出允许的使用范围，您需要直接从版权持有人获得许可。要查看此许可的副本，请访问 <http://creativecommons.org/licenses/by/4.0/>。

© 作者（们）2024